Duale Hochschule Baden-Württemberg Mannheim

**Praxisarbeit**

# Evaluierung des KI-Einsatzes zur nachhaltigen Materialentwicklung mit einem PLM-System

## Studiengang Informatik

### Studienrichtung Informationstechnik


| | |
|---|---|
| Verfasser: | Maksym Mykhailych |
| Matrikelnummer: | 9592553 |
| Firma: | Capgemini Deutschland GmbH |
| Abteilung: | Product Lifecycle Management/Digital Manufacturing |
| Kurs: | TINF24IT1 |
| Studiengangsleiter: | Prof. Dr. Gerhard Holger |
| Wissenschaftlicher Betreuer: | <Ihr(e) wissenschaftliche(r) Betreuer(in)> |
| Firmenbetreuer: | Alexander Zitterbart |
| Bearbeitungszeitraum: | 14.01.2026 – DD.MM.YYYY |

# Ehrenwörtliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit mit dem Titel "*Evaluierung des KI-Einsatzes zur nachhaltigen Materialentwicklung mit einem PLM-System* " selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Ort, Datum Maksym Mykhailych

# Sperrvermerk

**Ein Sperrvermerk sollte nur bei berechtigtem Bedarf gesetzt werden!**

**Beachten Sie, dass mit Sperrvermerk versehene Arbeiten nicht für weitere wissenschaftliche Zwecke außerhalb des Firmenkontextes oder zur Publikation verwendet werden dürfen.**

**Wir empfehlen, wenn möglich, auf den Sperrvermerk zu verzichten.**

**Besprechen Sie diese Problematik mit Ihrer Firma!**

(Mustertext) Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungsprozesses und des Evaluationsverfahrens zugänglich gemacht werden, sofern keine anders lautende Genehmigung der Ausbildungsstätte vorliegt.

# Danksagung

Hier können Sie eine Danksagung schreiben.

# Contents

**List of Figures** vi

**List of Tables** vii

**Quelltextverzeichnis** viii

**Algorithmenverzeichnis** ix

**Abkürzungsverzeichnis** x

**Kurzfassung (Abstract)** xi

**1 Einleitung** 1

**2 Theoretische und technische Grundlagen** 2
2.1 Einführung in das Product Lifecycle Management . . . 2
2.1.1 Konzept der PLM . . . 3
2.1.2 Produktlebenszyklusphasen . . . 3
2.1.3 PLM Grid und organisatorische Einbettung . . . 4
2.1.4 Definition von Product Data Management (PDM) . . . 5
2.1.5 Integration und Interoperabilität (CAD/CAE/CAM, ERP/MES/SCM) . 6
2.1.6 Digital Thread und Digital Twin im PLM-Kontext . . . 6
2.1.7 Beispielsystem: Siemens Teamcenter . . . 6
2.2 Künstliche Intelligenz und Machine Learning . . . 6
2.2.1 Grundlagen des Maschinellen Lernens . . . 7
2.2.2 Ansätze des Machine Learning . . . 7
2.2.3 Evaluierungsmetriken im Machine Learning . . . 10
2.2.4 Erklärbare Künstliche Intelligenz (XAI) . . . 11
2.2.5 Modelvertrauen . . . 12
2.3 Daten & Repräsentationen . . . 12
2.3.1 Datentypen . . . 13
2.3.2 Datenvorbereitung (Data Preprocessing) . . . 14
2.3.3 Feature Selection und Feature Engineering . . . 17
2.3.4 Physik-informiertes Machine Learning in der Materialwissenschaft . 17

**3 Materialentwicklung im industriellen Kontext** 18
3.1 Einführung in die Materialentwicklung . . . 18
3.1.1 Klassische Materialentwicklung . . . 18
3.1.2 Rechnergestützte Materialentwicklung . . . 19
3.2 (moderne) Materialentwicklung in der Automobilindustrie . . . 19
3.2.1 Materialvielfalt und Werkstoffen . . . 19
3.2.2 PLM-gestützte Materialdatenhaltung . . . 20

3.2.3 Zielkonflikte zwischen Kosten, Gewicht und Performance . . . . . 21
3.2.4 KI für die Materialentwicklung . . . . . 21
3.3 Materialdatenbanken & Datenquellen . . . . . 22

**4 Nachhaltigkeit in der Materialentwicklung 23**
4.1 Grundlage der Nachhaltigkeit . . . . . 23
4.2 Relevanz der Nachhaltigkeit in Zahlen . . . . . 24
4.3 Nachhaltigkeit der Materialien . . . . . 24
4.4 Lebenszyklusbetrachtung (LCA) . . . . . 25
4.4.1 Grundlage der LCA . . . . . 25
4.4.2 Methodische Weiterentwicklung . . . . . 25
4.4.3 Relevanz der LCA für diese Arbeit . . . . . 26
4.4.4 Systemgrenzen . . . . . 26
4.4.5 $CO_2$-Fußabdruck . . . . . 27

**5 Methodik der KI-gestützten Materialanalyse(CRISM-DM) 29**
5.1 Methodik CRISP-DM . . . . . 29

**6 KI-gestützte nachhaltige Materialentwicklung 31**
6.1 Toolsübersicht - Citrine . . . . . 31
6.2 APIs . . . . . 31
6.2.1 REST API . . . . . 32

**7 Evaluierung des KI-Einsatzes 33**
7.1 Evaluierungsstrategie . . . . . 33

**8 Beispiel-Kapitel: Noch ein Kapitel 34**
8.1 Abschnitt mit Coding . . . . . 34
8.2 Noch ein Abschnitt mit Coding . . . . . 34

**9 Zusammenfassung 35**
9.1 Fazit . . . . . 35
9.2 Ausblick . . . . . 35

**Anhang**

**A Beispiel-Anhang: Testanhang 36**
A.1 Abschnitt im Anhang . . . . . 36
A.2 Noch ein Abschnitt im Anhang . . . . . 36

**B Beispiel-Anhang: Noch ein Testanhang 38**

**Bibliography 39**

# List of Figures

2.1 Abbildung der PLM-Phase [5] . . . . . 4
2.2 Einordnung von Künstlicher Intelligenz, Maschinellem Lernen und Deep Learning [16] . . . . . 8
2.3 Zusammahang zwischen AI, Machine und Deep Learning(andere übeerschrift) [18] . . . . . 9
2.4 Zentrale Schritte der Datenvorbereitung im Data-Mining-Prozess(andere übeerschrift?!) [40] . . . . . 14

3.1 Verteilung der Werkstoffklassen im Automobilbau und deren relative Materialanteile. [55] . . . . . 20

5.1 Phasen des aktuellen CRISP-DM-Prozessmodells [**asdsasdas**] . . . . . 29

# List of Tables

# Quelltextverzeichnis

8.1 `PrintMovieDB.py` . . . . . 34

# Algorithmenverzeichnis

# Abkürzungsverzeichnis

**DHBW** Duale Hochschule Baden-Württemberg

**PLM** Product Lifecycle Management

# Kurzfassung (Abstract)

**Forschungsfragen:**

- Wie genau sagen KI-basierte Modelle materialwissenschaftliche Eigenschaften neuer Materialien im Vergleich zu Referenzdaten vorher?
- Welche technischen, organisatorischen und datenbezogenen Faktoren schränken den Einsatz KI-basierter Software in der nachhaltigen Materialentwicklung ein?
- In welchem Umfang trägt der Einsatz KI-basierter Materialentwicklungssoftware zur frühzeitigen Berücksichtigung von Nachhaltigkeitsaspekten bei?

Die Evaluation erfolgt als Cross-Database Benchmarking, in dem Citrine-Eigenschaften gegen unabhängige Datenbankwerte validiert werden; die Bewertung erfolgt über MAE/RMSE sowie Rangkorrelationen.

# 1 Einleitung

# 2 Theoretische und technische Grundlagen

Für eine nachvollziehbare Darstellung des Entwicklungsprozesses ist es erforderlich, die zugrunde liegenden Begriffe und Konzepte präzise und eindeutig zu definieren. Der folgende Abschnitt führt daher zentrale Fachtermini aus den Bereichen der PLM-Systeme, der Materialwissenschaft sowie der Künstlichen Intelligenz (KI) systematisch ein. Ziel ist es, eine einheitliche begriffliche Grundlage zu schaffen, die sowohl die theoretische Einordnung der Anwendung unterstützt als auch die methodische Absicherung der anschließenden Analyse gewährleistet.

## 2.1 Einführung in das Product Lifecycle Management

Product Lifecycle Management (PLM) bezeichnet die unternehmerische Tätigkeit, Produkte eines Unternehmens über ihren gesamten Lebenszyklus hinweg effizient zu steuern und zu verwalten – von der ersten Produktidee über Entwicklung, Markteinführung und Nutzung bis hin zur Außerbetriebnahme und Entsorgung. Dabei umfasst PLM sowohl die Verwaltung einzelner Produkte als auch des gesamten Produktportfolios, also der Gesamtheit aller im Unternehmen angebotenen Produkte. Der Fokus liegt auf der Begleitung der Produkte von der frühen Entwicklungsphase über Wachstums- und Reifephasen bis zum Ende ihres Lebenszyklus. Ziel des PLM ist es, Produktumsätze zu steigern, produktbezogene Kosten zu reduzieren, den Wert des Produktportfolios zu maximieren und sowohl für Kunden als auch für Anteilseigner einen nachhaltigen Mehrwert aus bestehenden und zukünftigen Produkten zu schaffen. [1]

In einer zunehmend datengetriebenen Welt, in der Informationen als strategische Ressource einen hohen wirtschaftlichen Wert besitzen, gewinnt PLM zusätzlich an Bedeutung. Die systematische Erfassung, Verwaltung und Nutzung von Produkt- und Prozessdaten über den gesamten Lebenszyklus hinweg ermöglicht fundierte Entscheidungen, höhere Transparenz sowie eine bessere Steuerung komplexer globaler Wertschöpfungsketten. Insgesamt eröffnen diese Entwicklungen vielfältige Marktchancen, die durch den gezielten Einsatz von PLM-Systemen effizient genutzt und nachhaltig gesteuert werden können. [2]

### 2.1.1 Konzept der PLM

Product Lifecycle Management (PLM) verfolgt das Ziel, sämtliche während aller Phasen des Produktlebenszyklus entstehenden Informationen nahtlos zu integrieren und organisationsweit verfügbar zu machen. Dabei richtet sich der Informationszugang nicht nur an interne Abteilungen, sondern schließt auch zentrale Lieferanten und Kunden mit ein. Durch den Einsatz von PLM können Hersteller die Zeit bis zur Markteinführung neuer Produktmodelle auf vielfältige Weise verkürzen. Insbesondere Produktentwickler profitieren von deutlich beschleunigten Prozessen zur Umsetzung und Freigabe von Konstruktionsänderungen entlang komplexer, unternehmensübergreifender Entwicklungsketten. Einkaufsabteilungen werden in die Lage versetzt, enger mit Lieferanten zusammenzuarbeiten und bestehende Bauteile effizient wiederzuverwenden. Gleichzeitig erhalten Führungskräfte eine ganzheitliche, übergeordnete Sicht auf alle relevanten Produktinformationen – von Details der Fertigungslinie über Ausfallraten einzelner Komponenten bis hin zu Garantie- und Felddaten. Diese umfassende Transparenz unterstützt fundierte strategische Entscheidungen und trägt maßgeblich zur Optimierung von Produktqualität, Kostenstruktur und Innovationsfähigkeit bei. [3]

### 2.1.2 Produktlebenszyklusphasen

Der Lebenszyklus eines Produkts lässt sich in fünf Phasen(Abb. 2.1) unterteilen, in denen sich das Produkt jeweils in einem unterschiedlichen Zustand befindet. In der Imaginationsphase existiert das Produkt zunächst ausschließlich als Idee. In der anschließenden Definitionsphase werden diese Ideen in eine konkrete und detaillierte Beschreibung überführt. Mit Abschluss der Realisierungsphase liegt das Produkt in seiner endgültigen Form vor, sodass es von Kunden genutzt werden kann, beispielsweise als serienreifes Fahrzeug. In der Nutzungs- und Servicephase befindet sich das Produkt beim Kunden und wird aktiv eingesetzt sowie gewartet. Schließlich erreicht das Produkt die End-of-Life-Phase, in der es aus wirtschaftlichen oder technischen Gründen nicht mehr genutzt wird, vom Unternehmen außer Betrieb genommen und vom Kunden entsorgt oder recycelt wird. [4]

Um einen reibungslosen Ablauf sicherzustellen und den wirtschaftlichen Erfolg des Produkts zu gewährleisten, ist eine durchgängige Steuerung über alle Lebenszyklusphasen hinweg erforderlich. Dieses ganzheitliche Management wird häufig als Betreuung des Produkts „von der Wiege bis zur Bahre“ beschrieben. Die ersten drei Phasen – Imagination, Definition und Realisierung – bilden zusammen den Beginning-ofLife (BOL) eines Produkts. Die Middle-of-Life-Phase (MOL) umfasst Aktivitäten wie Nutzung, Support und Instandhaltung. Die End-of-Life-Phase (EOL) schließt Prozesse wie Produktabkündigung, Entsorgung und Recycling ein. [6]

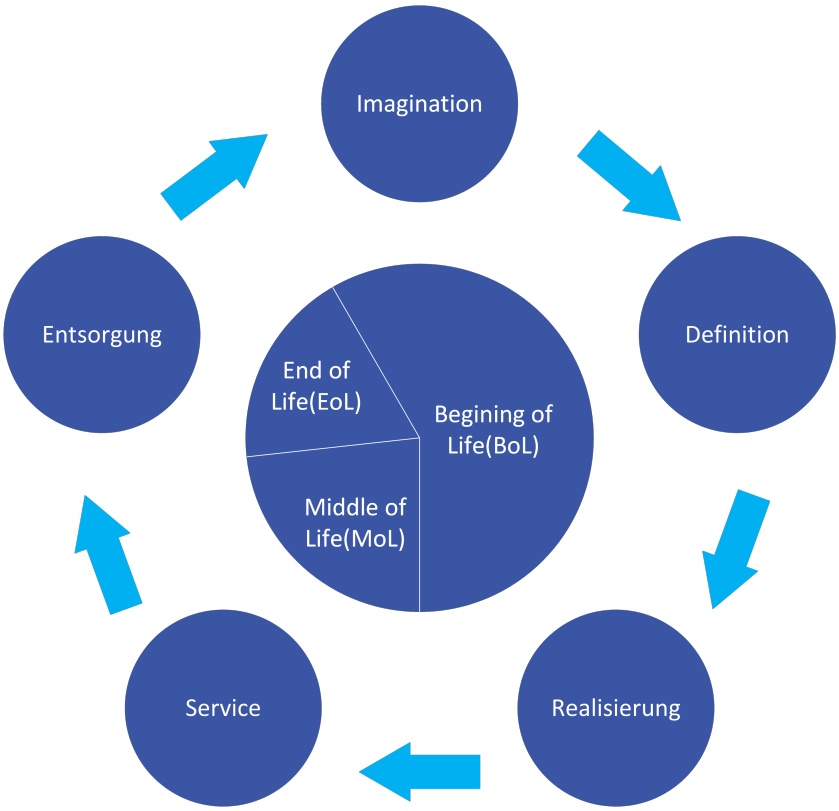


Figure 2.1: Abbildung der PLM-Phase [5]

Die durchgängige Betrachtung und Steuerung all dieser Phasen bildet die Grundlage für ein effektives Product Lifecycle Management eines Produktes.

### 2.1.3 PLM Grid und organisatorische Einbettung

Der Zweck des Product Lifecycle Managements (PLM) wird im sogenannten PLM-Grid veranschaulicht (Abb.). Das PLM-Grid stellt den Anwendungsbereich von PLM als zweidimensionale Matrix dar, in der auf der horizontalen Achse die fünf Phasen des Produktlebenszyklus und auf der vertikalen Achse die zu berücksichtigenden Komponenten wie Daten, Anwendungen und Aktivitäten abgebildet sind.

- **Objectives and KPI**: Die wesentlichen Ziele, die ein Unternehmen mit dem Einsatz von Product Lifecycle Management (PLM) verfolgt, bestehen in der ganzheitlichen Unterstützung und Durchführung aller PLM-bezogenen Aktivitäten. Die PLM-Ziele definieren und konkretisieren die Erwartungen an PLM in unterschiedlichen Bereichen, darunter insbesondere finanzielle Verbesserungen, die in der Regel höchste Priorität besitzen, Zeitersparnis, Qualitätssteigerung sowie die Weiterentwicklung und Optimierung von Geschäftsprozessen. Zur Operationalisierung dieser Ziele werden Kennzahlen in Form von Key Performance Indicators (KPIs) eingesetzt. KPIs unterstützen Unternehmen dabei, messbare Zielvorgaben zu definieren und den

Fortschritt sowie den Erfolg zukünftiger PLM-Aktivitäten systematisch zu überwachen und zu bewerten.

- **Organization and Management**: There are many resources to manage and a wide variety of resources in the PLM Environment.In addition to all this dimension, resources have complex interrelated relationships to manageproducts, components, and customers. Organizational structures, strategies and plans arenecessary to manage all these activities. The effective management of the organization andresources is so important that it can be called the necessity of PLM. No matter how good theresources from Human and Information Systems Applications are, all resources need to beorganized to achieve the PLM objectives. (Examples of organizations in the PLM environment:Departmental, flat, functional, hybrid, matrix, team, project etc.)

### 2.1.4 Definition von Product Data Management (PDM)

Product Data Management (PDM) bezeichnet wörtlich die Verwaltung von Produktdaten und beschreibt einen Ansatz sowie unterstützende Systeme zur zentralen Organisation aller produktrelevanten Informationen während der Produktentwicklung und Konstruktion. Dazu zählen unter anderem CAD-Modelle, Stücklisten (Bill of Materials, BOM), Versionierungsinformationen, technische Spezifikationen sowie Freigabe- und Änderungsprozesse (ECR/ECO) [7].

Im Kontext moderner Product-Lifecycle-Management-(PLM)-Ansätze wird PDM nicht mehr als isoliertes Softwaresystem verstanden, sondern als zentrale Informationsinfrastruktur. Ein PDM-System unterstützt Anwender bei der Durchführung ihrer Aufgaben durch die Integration unterschiedlicher funktionaler Modelle sowie durch die Anbindung weiterer Softwaresysteme. Damit bildet PDM die Grundlage für verschiedene Anwendungen und fungiert als Informationsmanagementsystem, in das zusätzliche Applikationen integriert werden können [8].

Diese zentrale Rolle ermöglicht eine konsistente Verwaltung produktbezogener Daten und Prozesse und unterstützt die Zusammenarbeit zwischen unterschiedlichen Abteilungen und Systemen über den gesamten Produktlebenszyklus hinweg [9].

### 2.1.5 Integration und Interoperabilität (CAD/CAE/CAM, ERP/MES/SCM)

### 2.1.6 Digital Thread und Digital Twin im PLM-Kontext

Aktuelle PLM-Diskussionen verknüpfen PLM zunehmend mit den Konzepten des Digital Thread und des Digital Twin, um durchgängige Datenflüsse und Rückkopplungen zwischen physischem Produkt und digitaler Repräsentation über den gesamten Lebenszyklus zu ermöglichen [1, 10].

...

### 2.1.7 Beispielsystem: Siemens Teamcenter

Für diese Arbeit werden öffentlich verfügbare Daten des Mars-Rover-Projekts verwendet, die in einem PLM-System auf Basis von Siemens Teamcenter verwaltet sind. Siemens Teamcenter ist ein umfassendes Product-Lifecycle-Management-System, das den gesamten Produktentstehungsprozess von der frühen Konzeptphase über Entwicklung und Fertigung bis hin zu Betrieb und Wartung unterstützt.

Teamcenter dient als zentrales Datenmanagementsystem (*Single Source of Truth*) zur Verwaltung von Stücklisten, Änderungen, Workflows, Simulationen und produktbezogenen Metadaten. Durch die zentrale Datenhaltung und Prozessintegration unterstützt das System die Zusammenarbeit zwischen beteiligten Disziplinen, steigert die Produktivität und trägt zur Reduktion von Fehlern und Kosten bei. [11]

## 2.2 Künstliche Intelligenz und Machine Learning

Die Künstliche Intelligenz (KI) gilt als eines der ältesten und zugleich breitesten Forschungsfelder der Informatik. Sie befasst sich mit der Nachbildung kognitiver Fähigkeiten zur Lösung realweltlicher Probleme sowie mit der Entwicklung von Systemen, die lernen und denken können. Zur Abgrenzung von menschlicher Intelligenz wird in diesem Zusammenhang häufig auch der Begriff der maschinellen Intelligenz verwendet. [12]

Aktuelle Forschungsarbeiten betonen erneut, dass KI-Systeme über reine Mustererkennung hinausgehen sollten. Stattdessen wird gefordert, dass sie kausale Modelle der Welt

aufbauen, die erklärbares Verhalten, Verständnis und fundierte Schlussfolgerungen ermöglichen. Diese Perspektive verbindet moderne maschinelle Lernverfahren mit strukturierten, kognitiv inspirierten Modellen und stellt einen wichtigen Entwicklungsschritt für erklärbare und vertrauenswürdige KI-Systeme dar. [13]

In den nachfolgenden Kapiteln werden die grundlegenden theoretischen und methodischen Grundlagen der Künstlichen Intelligenz dargelegt.

### 2.2.1 Grundlagen des Maschinellen Lernens

Maschinelles Lernen (Machine Learning, ML) stellt ein besonders praxisnahes Teilgebiet der Künstlichen Intelligenz dar. Es befasst sich mit der Entwicklung von Algorithmen, die in der Lage sind, aus vorhandenen Daten selbstständig zu lernen, Wissen aus Erfahrung abzuleiten und auf dieser Basis statistische Modelle für Analyse- und Vorhersageaufgaben zu erstellen. Ziel ist es, Systeme zu entwickeln, die ohne explizite Programmierung für eine spezifische Aufgabe Muster in Daten erkennen und verlässliche Prognosen für neue, unbekannte Daten treffen können. [14]

Zentrale Herausforderungen im ML betreffen insbesondere die Modellierung komplexer und hochdimensionaler Daten, die Bildung aussagekräftiger Repräsentationen sowie die Entscheidungsfindung unter Unsicherheit. Aufgrund seiner breiten Anwendbarkeit stellt ML einen Kernbestandteil moderner KI-Systeme dar und unterstützt datenbasierte Entscheidungsprozesse in Wissenschaft und Industrie. Neben den theoretischen Fortschritten haben insbesondere in den vergangenen Jahren die praktischen Anwendungen des MLs erheblich zugenommen. Diese Entwicklung wird nicht nur von Informatikern und KI-Forschern vorangetrieben, sondern auch von Wissenschaftlern anderer Disziplinen, die ML-Methoden zur Lösung fachbezogener Fragestellungen einsetzen. [15]

Eine besondere Rolle nimmt dabei das Deep Learning ein, ein Teilgebiet des maschinellen Lernens (Abb. 2.2), das auf künstlichen neuronalen Netzen basiert. Deep-Learning-Methoden haben in den vergangenen Jahren maßgeblich zum Leistungszuwachs moderner KI-Systeme beigetragen und eröffnen neue Anwendungsfelder, insbesondere bei der Verarbeitung großer und komplexer Datenmengen. [17]

### 2.2.2 Ansätze des Machine Learning

KI-Systeme lassen sich anhand ihrer Lernstrategie klassifizieren. Abhängig von der Art des Lernprozesses können die folgenden Hauptkategorien (Abb. 2.3) unterschieden werden [18]

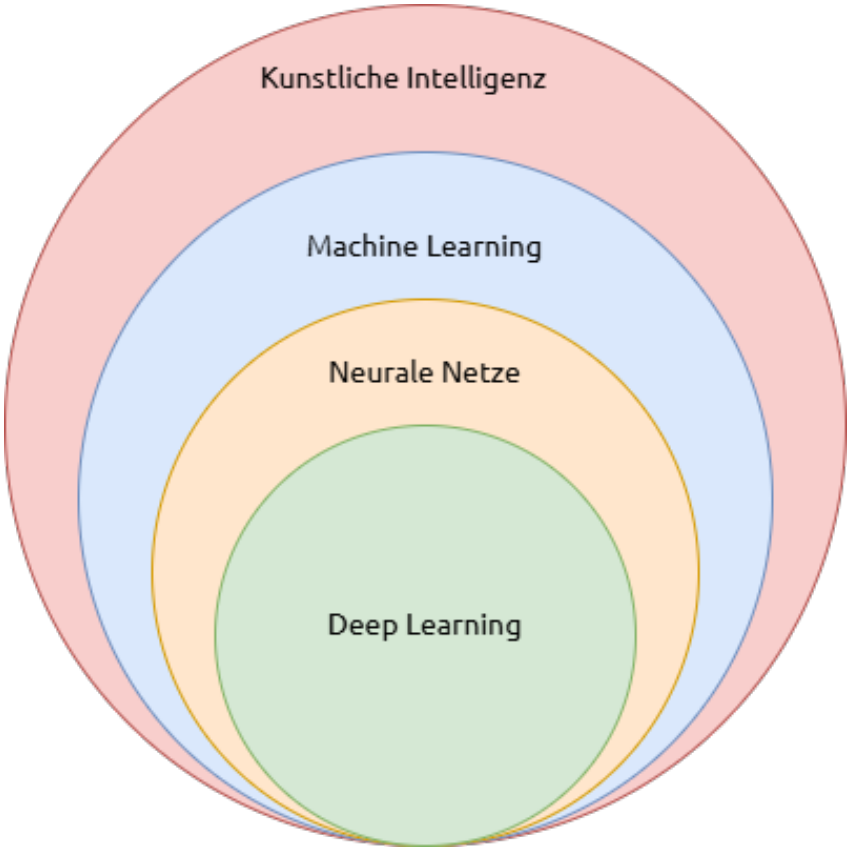


Figure 2.2: Einordnung von Künstlicher Intelligenz, Maschinellem Lernen und Deep Learning [16]

**Überwachtes Lernen (Supervised Learning)**

Beim überwachten Lernen wird ein Modell anhand gelabelter Trainingsdaten trainiert, bei denen zu jeder Eingabevariable $X$ eine bekannte Zielvariable $Y$ vorliegt. Ziel ist es, eine Abbildungsfunktion zu erlernen, die es ermöglicht, für neue, bislang unbekannte Eingaben korrekte Ausgaben vorherzusagen. [19]

Wie in der Abbildung dargestellt, lassen sich zwei Hauptaufgabentypen unterscheiden:

- **Klassifikation**: Die Zielvariable ist diskret, und das Modell ordnet Eingabedaten vordefinierten Klassen zu (z. B. Trennung von Datenpunkten in verschiedene Kategorien).
- **Regression**: Die Zielvariable ist kontinuierlich, und das Modell sagt numerische Werte voraus (z. B. eine lineare Beziehung zwischen Eingabe- und Ausgabedaten).

Supervised Learning wird häufig eingesetzt, wenn ausreichend gelabelte Daten verfügbar sind und konkrete Vorhersagen oder Entscheidungen getroffen werden sollen.

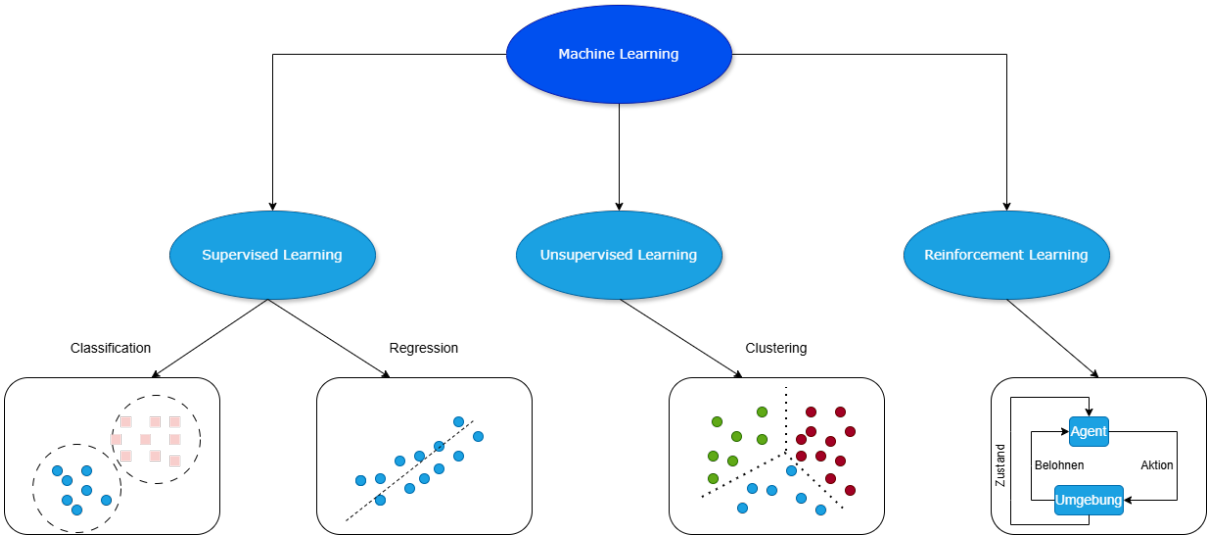


Figure 2.3: Zusammahang zwischen AI, Machine und Deep Learning(andere übeerschrift) [18]

### Unüberwachtes Lernen (Unsupervised Learning)

Im Gegensatz dazu arbeitet das unüberwachte Lernen ohne gelabelte Zielwerte. Das Modell erhält ausschließlich Eingabedaten $X$ und versucht, selbstständig Strukturen, Muster oder Zusammenhänge innerhalb der Daten zu identifizieren. In der Abbildung ist als typisches Beispiel das **Clustering** dargestellt. Dabei werden Datenpunkte anhand von Ähnlichkeiten in Gruppen eingeteilt, ohne dass diese Gruppen zuvor definiert sind. Ziel ist es, verborgene Strukturen oder natürliche Gruppierungen in den Daten sichtbar zu machen. Unsupervised Learning eignet sich insbesondere für explorative Analysen, Vorverarbeitungsschritte sowie für Anwendungen, bei denen keine oder nur schwer zu beschaffende Labels vorliegen. [20]

### Bestärkendes Lernen (Reinforcement Learning)

Das bestärkende Lernen (Reinforcement Learning) unterscheidet sich grundlegend vom überwachten und unüberwachten Lernen. E in Agent lernt nicht aus gelabelten Beispielen oder aus statischen Datenstrukturen, sondern durch fortlaufende Interaktion mit einer Umgebung. Der Agent wählt in einem gegebenen Zustand eine Aktion aus und erhält als Rückmeldung eine Belohnung oder Bestrafung. Ziel des Lernprozesses ist es, eine optimale Strategie (Policy) zu erlernen, die den langfristigen kumulierten Belohnungswert maximiert. Dabei entsteht das Wissen schrittweise durch Versuch und Irrtum. [21]

Reinforcement Learning eignet sich insbesondere für Entscheidungs- und Steuerungsprobleme, bei denen die Konsequenzen von Aktionen zeitlich verzögert auftreten und keine

expliziten Zielwerte vorgegeben sind. Typische Anwendungsbereiche sind unter anderem Robotik, autonome Systeme, Spiele, Prozesssteuerung sowie adaptive Optimierungsprobleme. [22]

Neben den klassischen überwachten und unüberwachten Lernverfahren haben sich in den letzten Jahren weitere Lernparadigmen etabliert. Semi-Supervised Learning kombiniert kleine Mengen gelabelter Daten mit großen Mengen ungelabelter Daten, während Self-Supervised Learning automatisch Lernziele aus den Daten selbst ableitet. Diese Ansätze sind insbesondere bei datenknappen industriellen Anwendungen von hoher Relevanz. [23] [24]

### 2.2.3 Evaluierungsmetriken im Machine Learning

(Vllt. in die Evaluierungskapitel....) Die Evaluation von Machine-Learning-Modellen ist ein zentraler Bestandteil datengetriebener Analysen, da sie eine objektive Beurteilung der Modellleistung ermöglicht. Evaluierungsmetriken dienen dazu, die Abweichung zwischen vorhergesagten Modellwerten und bekannten Referenzwerten quantitativ zu erfassen und unterschiedliche Modelle oder Modellkonfigurationen vergleichbar zu machen. Eine geeignete Wahl der Metriken ist dabei entscheidend, da unterschiedliche Fehlermaße unterschiedliche Aspekte der Modellgüte betonen.

#### MAE (Mean Absolute Error)

Der Mean Absolute Error (MAE) misst den durchschnittlichen absoluten Vorhersagefehler:

$$\mathrm{MAE} \;=\; \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i| \,. \tag{2.1}$$

MAE ist besonders geeignet, wenn Fehler *linear* bestraft werden sollen und wenn Robustheit gegenüber Ausreißern wünschenswert ist, da die Fehler nicht quadriert werden. [26]

#### RMSE (Root Mean Squared Error)

Der Root Mean Squared Error (RMSE) ist die Wurzel des mittleren quadratischen Fehlers:

$$\mathrm{RMSE} \;=\; \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}. \tag{2.2}$$

RMSE gewichtet große Fehler stärker (Quadrat), wodurch er sinnvoll ist, wenn seltene große Abweichungen besonders schädlich sind. Gleichzeitig ist RMSE unter bestimmten

Annahmen statistisch natürlich: Bei näherungsweise normalverteilten Fehlern (Gaussian errors) ist RMSE als Maß der „typischen“ Streuung besonders passend. [27]

**$R^2$ (Koeffizient der Determination)**

Der Determinationskoeffizient $R^2$ misst (in einer verbreiteten Form) den Anteil der Varianz von $y$, der durch das Modell erklärt wird, und ist wie folgt definiert:

$$R^2 \;=\; 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}. \tag{2.3}$$

$R^2$ hat eine wichtige Baseline-Interpretation: Der Wert $R^2 = 0$ entspricht einer trivialen Vorhersage durch die horizontale Linie $y = \bar{y}$ (Mittelwert-Prädiktor), und negative Werte bedeuten, dass das Modell schlechter ist als diese Baseline. Damit eignet sich $R^2$ gut, um *relativ* zur Datenvariabilität zu kommunizieren, ob ein Modell überhaupt über ein naives Mittelwertmodell hinausgeht. [28]

Die hier vorgestellten Evaluierungsmetriken werden im weiteren Verlauf der Arbeit zur quantitativen Bewertung der KI-basierten Vorhersagen eingesetzt und im Evaluierungskapitel im Kontext der Materialentwicklung interpretiert.

(student T'Distribution?!)

### 2.2.4 Erklärbare Künstliche Intelligenz (XAI)

Der zunehmende Einsatz Künstlicher Intelligenz in industriellen Anwendungen, insbesondere im Automobilbau, erfordert ein hohes Maß an Transparenz und Nachvollziehbarkeit der getroffenen Modellentscheidungen. In diesem Kontext gewinnt erklärbare Künstliche Intelligenz (Explainable Artificial Intelligence, XAI) an Bedeutung, da sie Einblicke in die Entscheidungslogik datengetriebener Modelle ermöglicht und somit Vertrauen in KI-gestützte Systeme schafft. [29]

Gerade im Bereich der nachhaltigen Material- und Prozessentwicklung, etwa bei der Auswahl von Werkstoffen oder der Optimierung energieintensiver Fertigungsschritte wie Beschichtungs- und Lackierprozessen, ist die Interpretierbarkeit von KI-Modellen von zentraler Bedeutung. Moderne Machine-Learning-Verfahren, darunter Ensemble-Modelle, tiefe neuronale Netze oder Support-Vector-Methoden, liefern zwar hohe Vorhersagegenauigkeiten, agieren jedoch häufig als Black-Box-Modelle. Dies erschwert es, die zugrunde liegenden Zusammenhänge zwischen Materialeigenschaften, Prozessparametern, Kosten und Umweltwirkungen zu verstehen. [30]

XAI-Methoden adressieren diese Herausforderung, indem sie den Einfluss einzelner Eingangsgrößen auf Modellvorhersagen quantifizieren und visualisieren. Verfahren wie SHapley Additive exPlanations (SHAP) oder Local Interpretable Model-Agnostic Explanations (LIME) ermöglichen es beispielsweise, aufzuzeigen, welche Materialparameter oder Prozessschritte maßgeblich zu erhöhtem Energieverbrauch, Kosten oder Emissionen beitragen. Im PLM-Kontext lassen sich diese Erklärungen direkt mit produkt- und prozessbezogenen Daten verknüpfen, sodass Entscheidungen entlang des gesamten Produktlebenszyklus nachvollziehbar und datenbasiert getroffen werden können. [31]

- **SHapley Additive exPlanations (SHAP):** SHAP basiert auf spieltheoretischen Shapley-Werten und quantifiziert den Beitrag einzelner Eingangsmerkmale zur Modellvorhersage. Die Methode liefert sowohl lokale Erklärungen für einzelne Vorhersagen als auch globale Aussagen über die Merkmalswichtigkeit. SHAP eignet sich insbesondere zur Analyse komplexer Modelle und ermöglicht eine konsistente und vergleichbare Interpretation von Material- und Prozessparametern.[32]
- **Local Interpretable Model-Agnostic Explanations (LIME):** LIME erklärt Modellentscheidungen lokal, indem es die Vorhersage eines komplexen Modells in der Umgebung eines einzelnen Datenpunkts durch ein einfaches, interpretierbares Ersatzmodell approximiert. Dadurch lassen sich die wichtigsten Einflussfaktoren für eine konkrete Vorhersage identifizieren. LIME ist modellagnostisch und besonders geeignet für fallbezogene Analysen und Entscheidungsunterstützung. [33]

Zahlreiche aktuelle Studien zeigen, dass XAI-Methoden erfolgreich eingesetzt werden können, um kritische Designparameter zu identifizieren, Materialeigenschaften gezielt zu optimieren und die Zuverlässigkeit datengetriebener Modelle in unterschiedlichen materialwissenschaftlichen Anwendungen zu erhöhen. Damit stellt erklärbare Künstliche Intelligenz einen entscheidenden Baustein für den verantwortungsvollen und nachhaltigen Einsatz von KI in der Materialentwicklung und im Engineering dar. [34] [35]

### 2.2.5 Modelvertrauen

## 2.3 Daten & Repräsentationen

Um ein KI-Modell valide zu trainieren, ist die korrekte Interpretation und Aufbereitung der zugrunde liegenden Daten von zentraler Bedeutung. Fehlerhafte, inkonsistente oder unvollständige Datensätze können den Lernprozess erheblich beeinträchtigen und zu verzerrten oder nicht belastbaren Vorhersagen führen. Eine systematische Analyse der Datentypen sowie eine sorgfältige Datenvorbereitung bilden daher die Grundlage für leistungsfähige und zuverlässige KI-Modelle.

### 2.3.1 Datentypen

Im Kontext der KI-gestützten Materialentwicklung und des Product Lifecycle Managements (PLM) lassen sich relevante Datentypen in drei Hauptkategorien einteilen: strukturierte, semi-strukturierte und unstrukturierte Daten. Diese Klassifikation ist insbesondere für die Bewertung der Datenqualität, der Integrationsfähigkeit sowie der Eignung für maschinelle Lernverfahren von Bedeutung. [36]

#### Unstrukturierte Daten

Unstrukturierte Daten besitzen keine feste oder vordefinierte Datenstruktur und liegen in heterogenen Formaten vor. Im industriellen Materialkontext umfassen sie beispielsweise Laborberichte, Versuchsprotokolle, wissenschaftliche Publikationen, PDF-Dokumente, Bilder von Mikrostrukturen oder Messkurven aus experimentellen Untersuchungen. Diese Daten enthalten häufig wertvolles Expertenwissen, sind jedoch für automatisierte Analysen nur eingeschränkt nutzbar und erfordern aufwendige Vorverarbeitungsschritte wie Textanalyse, Bildverarbeitung oder semantische Annotation. [37]

#### Semi-strukturierte Daten

Semi-strukturierte Daten weisen eine partielle Struktur auf, die jedoch nicht den strengen Anforderungen relationaler Datenbanksysteme entspricht. Typische Beispiele im PLM-Umfeld sind XML- oder JSON-basierte Austauschformate, Materialdatenblätter, Metadatenbeschreibungen sowie standardisierte Schnittstellenformate. Diese Datentypen stellen einen wichtigen Vermittler zwischen unstrukturierten Dokumenten und strukturierten Datenbanken dar und ermöglichen eine flexible, aber dennoch maschinenlesbare Repräsentation materialbezogener Informationen. [38]

#### Strukturierte Daten

Strukturierte Daten liegen in klar definierten Schemata vor und werden üblicherweise in relationalen Datenbanksystemen gespeichert. Im Kontext der Materialentwicklung umfassen sie unter anderem Materialkennwerte, Stücklisten (BOM), Prozessparameter, Simulationsergebnisse sowie Lebenszyklus- und Nachhaltigkeitskennzahlen. Insbesondere PLM- und ERP-Systeme generieren prozessvermittelte strukturierte Daten, die eine konsistente Analyse, Vergleichbarkeit und Integration in KI-gestützte Entscheidungsmodelle ermöglichen. [39]

### 2.3.2 Datenvorbereitung (Data Preprocessing)

Nachdem die verschiedenen Datentypen erläutert wurden, wird im Folgenden beschrieben, wie Daten für Analyse- und Data-Mining-Zwecke vorbereitet werden. Die Datenvorbereitung stellt in der Regel einen unverzichtbaren Schritt im Data-Mining-Prozess dar. Sie dient dazu, ursprünglich ungeeignete oder unvollständige Rohdaten in eine Form zu überführen, die für Data-Mining-Algorithmen nutzbar ist. Ohne eine angemessene Datenvorbereitung kann ein Algorithmus entweder nicht korrekt ausgeführt werden oder während der Laufzeit Fehler erzeugen. Selbst in Fällen, in denen der Algorithmus formal erfolgreich ausgeführt wird, sind die resultierenden Ergebnisse häufig nicht aussagekräftig oder können nicht als verlässliches Wissen interpretiert werden. [40]

Vor diesem Hintergrund stellt sich die Frage, welche grundlegenden Problemstellungen im Rahmen der Datenvorbereitung adressiert werden müssen. Im Folgenden werden zentrale Fragestellungen der Datenvorbereitung aufgeführt und den jeweils zugehörigen Techniken zugeordnet (Abb. 2.4): [41]

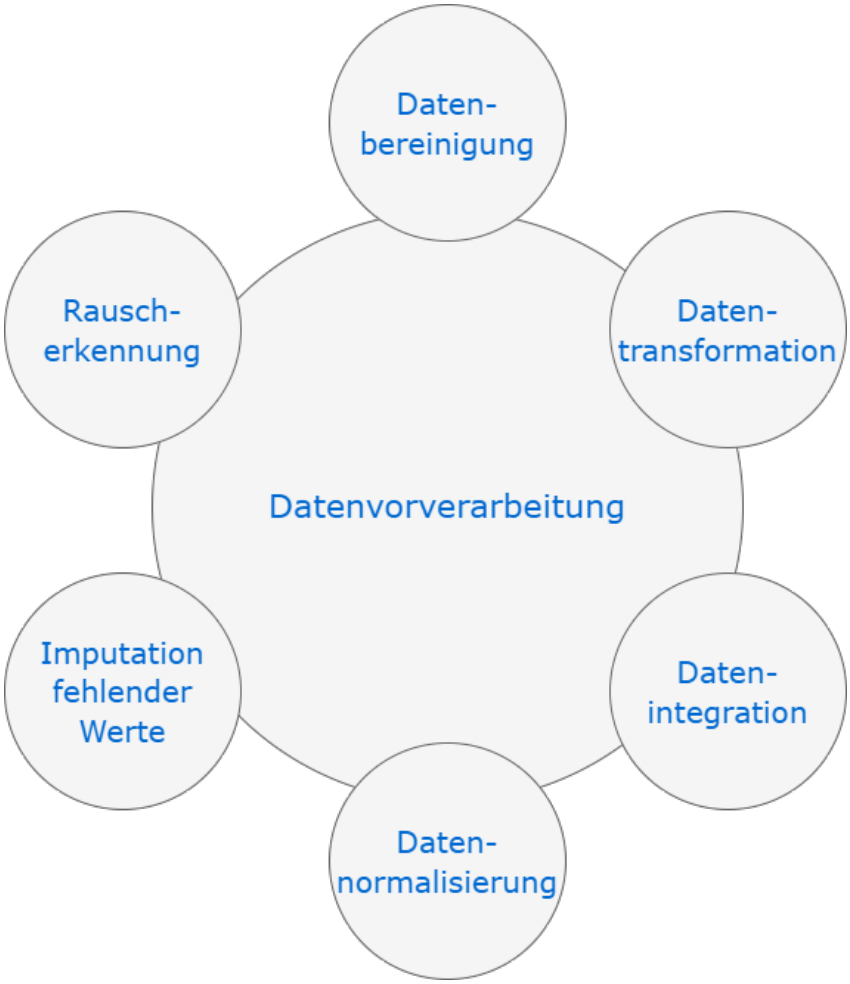


Figure 2.4: Zentrale Schritte der Datenvorbereitung im Data-Mining-Prozess(andere übeerschrift?!) [40]

- **Datenbereinigung (Data Cleaning)**: Rohdaten enthalten häufig unvollständige Datensätze, Rauschen, Ausreißer sowie inkonsistente oder fehlerhafte Werte. Die Datenbereinigung stellt daher einen der ersten und wichtigsten Schritte im Rahmen der Datenvorverarbeitung dar. Ziel dieses Prozesses ist es, fehlende Werte zu identifizieren, verrauschte Daten zu glätten, Ausreißer zu erkennen sowie inkonsistente oder fehlerhafte Einträge zu korrigieren. Solche sogenannten „verschmutzten“ Daten können den Data-Mining-Prozess erheblich beeinträchtigen und zu unzuverlässigen oder qualitativ schlechten Ergebnissen führen. Selbst leistungsfähige Analyse- und Lernalgorithmen sind nicht in der Lage, fehlerhafte Eingabedaten zu kompensieren. Aus diesem Grund ist der Einsatz geeigneter Datenbereinigungsroutinen von zentraler Bedeutung, um die Qualität der Daten und damit die Aussagekraft der resultierenden Modelle zu verbessern. Typische Verfahren der Datenbereinigung umfassen unter anderem die Behandlung fehlender Werte, die Erkennung und Entfernung von Duplikaten, die Identifikation von Ausreißern sowie die Korrektur inkonsistenter Datenformate oder Wertebereiche. Tabelle 1 zeigt beispielhaft einen Datensatz mit fehlerhaften beziehungsweise unvollständigen Einträgen. [42]

- **Datentransformation (Data Transformation)**: In diesem Schritt der Datenvorverarbeitung werden Daten umgewandelt oder zusammengeführt, um den Data-Mining-Prozess effizienter zu gestalten und die Anwendbarkeit der Ergebnisse zu verbessern. Die Datentransformation umfasst verschiedene Teilaufgaben wie Glättung von Daten, Merkmalskonstruktion, Aggregation bzw. Zusammenfassung von Daten, Normalisierung, Diskretisierung sowie Generalisierung. Viele dieser Schritte können als eigenständige Aufgaben betrachtet werden, da die Datentransformation – ähnlich wie die Datenbereinigung – eine allgemeine Klasse von Vorverarbeitungstechniken darstellt. Bestimmte Transformationsaufgaben erfordern jedoch menschliche Expertise und sind stark datenabhängig, etwa die Erstellung aggregierter Attribute, die Generierung von Berichten oder die Generalisierung kategorialer Merkmale, beispielsweise durch die Ersetzung vollständiger Datumsangaben durch Jahreswerte. [43]

- **Datenintegration (Data Integration)**: Die Datenintegration umfasst die Zusammenführung von Daten aus mehreren Datenquellen zu einem konsistenten Gesamtdatensatz. Dieser Prozess muss sorgfältig durchgeführt werden, um Redundanzen und Inkonsistenzen in den integrierten Daten zu vermeiden. Typische Aufgaben der Datenintegration sind die Identifikation und Vereinheitlichung von Variablen und Wertebereichen, die Analyse von Attributkorrelationen, die Erkennung und Behandlung von Duplikaten sowie die Auflösung widersprüchlicher Datenwerte aus unterschiedlichen Quellen. [44]

- **Datennormalisierung (Data Normalization)**: Die verwendeten Maßeinheiten und Wertebereiche einzelner Attribute können die Ergebnisse von Datenanalysen maßge-

blich beeinflussen. Daher sollten alle Attribute in einheitlichen Maßeinheiten vorliegen und eine gemeinsame Skala oder einen vergleichbaren Wertebereich verwenden. Die Datennormalisierung zielt darauf ab, allen Attributen ein gleiches Gewicht im Analyse- oder Lernprozess zu geben. Dieser Schritt ist insbesondere für statistische Lernverfahren und distanzbasierte Algorithmen von großer Bedeutung. Im materialwissenschaftlichen Kontext ist die Vereinheitlichung physikalischer Einheiten (z.B. MPa, GPa, °C) von besonderer Bedeutung, da inkonsistente Skalierungen physikalisch nicht interpretierbare Modelle begünstigen können. [45]

- **Imputation fehlender Werte (Missing Data Imputation)**: Die Imputation fehlender Werte ist ein Bestandteil der Datenbereinigung und hat das Ziel, Variablen mit fehlenden Werten durch geeignete Schätzungen zu ergänzen. In vielen Fällen ist es sinnvoller, fehlende Einträge durch plausible Werte zu ersetzen, als sie unbehandelt zu lassen, da zahlreiche Analyse- und Lernverfahren keine fehlenden Werte verarbeiten können. Die Wahl der Imputationsmethode hängt vom Datentyp, der Datenverteilung sowie vom Anwendungsfall ab. [46]
- **Rauscherkennung (Noise Identification)**: Die Rauscherkennung ist ebenfalls Teil der Datenbereinigung und wird in der Datentransformation häufig als Glättung bezeichnet. Ihr Hauptziel besteht in der Identifikation zufälliger Fehler oder unerwünschter Variationen in Messwerten. Dabei liegt der Fokus auf der Erkennung von Rauschen, nicht auf dessen Entfernung, die typischerweise dem Bereich der Datenreduktion zuzuordnen ist. Nach der Identifikation verrauschter Datenpunkte können korrekturbasierte Verfahren angewendet werden, um deren Einfluss auf nachfolgende Analyse- oder Lernprozesse zu reduzieren. [45]

#### Data Leakage

Ein zentrales Risiko im Rahmen der Datenvorbereitung stellt auch die sogenannte Datenleckage dar. Im Kontext der Materialentwicklung und des Product Lifecycle Managements (PLM) bezeichnet Datenleckage die unbeabsichtigte oder unautorisierte Weitergabe sensibler produkt- und materialbezogener Informationen, wie Materialrezepturen, Prozessparameter, Simulationsergebnisse oder Entwicklungsstände. Da PLM-Systeme als zentrale Datenplattformen kritische Informationen über den gesamten Produktlebenszyklus bündeln und mit externen Systemen sowie Partnern vernetzt sind, stellt Datenleckage ein erhebliches Risiko für den Schutz geistigen Eigentums dar. Insbesondere bei daten- und KI-gestützten Materialentwicklungsprozessen ist daher ein konsequentes Daten- und Zugriffsmanagement erforderlich. [47] [48]

### 2.3.3 Feature Selection und Feature Engineering

Neben der technischen Aufbereitung der Daten spielt auch die Auswahl und Konstruktion geeigneter Merkmale eine zentrale Rolle für die Leistungsfähigkeit von KI-Modellen. Im Rahmen der Datenvorbereitung ist zwischen Feature Engineering und Feature Selection zu unterscheiden. Feature Engineering bezeichnet die gezielte Erzeugung oder Transformation von Merkmalen, um relevante Informationen aus Rohdaten besser für maschinelle Lernverfahren nutzbar zu machen. Feature Selection hingegen zielt darauf ab, aus einer gegebenen Merkmalsmenge irrelevante, redundante oder stark korrelierte Attribute zu entfernen. Dies kann die Modellkomplexität reduzieren, die Interpretierbarkeit erhöhen und das Risiko von Overfitting verringern. Beide Ansätze ergänzen sich und spielen insbesondere bei hochdimensionalen Material- und Prozessdaten eine zentrale Rolle. [49]

### 2.3.4 Physik-informiertes Machine Learning in der Materialwissenschaft

Physics-informiertes Machine Learning (PIML) beschreibt eine Klasse von Methoden, die physikalisches Vorwissen gezielt mit datengetriebenen Machine-Learning-Ansätzen kombinieren, um komplexe physikalische Systeme robuster und effizienter zu modellieren. Der Ansatz adressiert die Grenzen klassischer numerischer Simulationsverfahren sowie rein datengetriebener Lernmodelle, insbesondere bei multiphysikalischen, multiskaligen und datenarmen Problemstellungen. Während physikbasierte Modelle typischerweise eine vollständige Kenntnis der zugrunde liegenden Gleichungen sowie wohldefinierte Anfangs- und Randbedingungen erfordern, sind sie in realen Anwendungen häufig durch hohen Rechenaufwand, Modellunsicherheiten und fehlende Messdaten eingeschränkt. Rein datengetriebene Deep-Learning-Modelle hingegen sind zwar flexibel, liefern jedoch ohne zusätzliche Einschränkungen oft physikalisch inkonsistente oder schlecht generalisierende Ergebnisse. [**karniadakis2021physics**]

# 3 Materialentwicklung im industriellen Kontext

In diesem Kapitel wird das Thema Materialentwicklung behandelt...

## 3.1 Einführung in die Materialentwicklung

Materialien bilden die Grundlage nahezu aller technologischen Entwicklungen. Fortschritte in Bereichen wie Energieumwandlung, Informations- und Kommunikationstechnologie, Mobilität, Medizintechnik oder nachhaltiger Produktion sind unmittelbar an die Verfügbarkeit neuer oder verbesserter Materialien gekoppelt. Historisch betrachtet markieren neue Werkstoffe – etwa Bronze, Stahl, Halbleiter oder Polymere – jeweils technologische Umbrüche ganzer Zivilisationen. Entsprechend gilt die Materialentwicklung als eine der zentralen Triebfedern technologischen Fortschritts. [50]

### 3.1.1 Klassische Materialentwicklung

Trotz dieser langen Forschungstradition befindet sich die Materialwissenschaft heute an einem paradoxen Punkt: Einerseits existiert ein umfangreiches Wissen über Struktur-Eigenschafts-Beziehungen bekannter Materialien, andererseits ist der überwiegende Teil des theoretisch möglichen Materialraums bislang unerforscht. Aktuelle Abschätzungen gehen davon aus, dass bisher lediglich etwa 1 % aller theoretisch möglichen chemischen Verbindungen synthetisiert und charakterisiert wurden. Der verbleibende Teil stellt einen weitgehend unerschlossenen Raum mit potenziell neuartigen und teilweise revolutionären Eigenschaften dar, etwa für Anwendungen in der Energiespeicherung, Katalyse, Quantentechnologien oder der Biomedizin. [51]

Aufgrund des hohen Zeit- und Kostenaufwands ist die systematische Erschließung dieses enormen Suchraums mit klassischen experimentellen Methoden jedoch kaum zu bewältigen. Die Motivation moderner Materialentwicklung liegt daher zunehmend in der Beschleunigung der Entdeckung neuer Materialien(wegen der neuer Regulatorik, ), insbesondere durch datengetriebene, rechnergestützte und automatisierte Ansätze. [52]

### 3.1.2 Rechnergestützte Materialentwicklung

Die rechnergestützte Materialentwicklung zielt darauf ab, experimentelle Entwicklungsprozesse durch simulations- und datenbasierte Methoden zu ergänzen oder teilweise zu ersetzen. Zentrale Ansätze sind dabei physikbasierte Simulationen, insbesondere Methoden der Dichtefunktionaltheorie (DFT), mit denen elektronische, mechanische und thermodynamische Materialeigenschaften berechnet werden können. Darüber hinaus ermöglichen High-Throughput-Simulationen die systematische Untersuchung großer Materialräume, indem tausende potenzieller Materialkombinationen automatisiert bewertet werden. Diese Ansätze reduzieren den experimentellen Aufwand erheblich, sind jedoch weiterhin mit hohen Rechenkosten verbunden und skalieren nur begrenzt auf komplexe industrielle Randbedingungen. Vor diesem Hintergrund gewinnen datengetriebene Methoden zunehmend an Bedeutung, da sie rechnergestützte Ergebnisse mit experimentellen Daten kombinieren und so eine effizientere Exploration des Materialraums ermöglichen. [53]

#### Dichtefunktionaltheorie (DFT) und Simulation

## 3.2 (moderne) Materialentwicklung in der Automobilindustrie

Die Automobilindustrie zählt zu den material- und ressourcenintensivsten Industriezweigen und stellt daher ein zentrales Anwendungsfeld moderner Materialentwicklung dar. Fahrzeuge bestehen aus einer Vielzahl unterschiedlicher Werkstoffe, deren Auswahl und Kombination maßgeblichen Einfluss auf Gewicht, Sicherheit, Kosten, Energieverbrauch sowie ökologische Auswirkungen über den gesamten Produktlebenszyklus hinweg haben.

### 3.2.1 Materialvielfalt und Werkstoffen

Die Auswahl geeigneter Werkstoffe stellt insbesondere im Automobilbau einen zunehmend datengetriebenen Entscheidungsprozess dar. Fahrzeuge bestehen aus einer Vielzahl unterschiedlicher Materialien, darunter Stahl, Aluminium, Magnesium, Kunststoffe sowie Faserverbundwerkstoffe wie kohlenstofffaserverstärkte Kunststoffe. Die Bewertung dieser Werkstoffe erfordert die Berücksichtigung zahlreicher Kriterien, darunter mechanische, thermische und chemische Eigenschaften, Herstellbarkeit, Lebensdauer, Kosten sowie ökologische Auswirkungen. [54]

Fahrzeuge bestehen aus einer Vielzahl unterschiedlicher Materialien (Abb. 3.1), darunter Metalle, Polymere, Kunststoffe und Faserverbundwerkstoffe, deren Nachhaltigkeit entlang

des gesamten Produktlebenszyklus bewertet und optimiert werden muss. Mehr als die Hälfte des gesamten Materialvolumens eines modernen Fahrzeugs entfällt auf Gusseisen- und Stahlbauteile (ca. 55 %). Kunststoffe machen etwa 11 % aus, gefolgt von Aluminiumlegierungen mit rund 9 %. Weitere Materialanteile entfallen auf Gummi (ca. 7 %) und Glas (ca. 3 %), während der Anteil von Nichteisenlegierungen wie Magnesium, Titan, Kupfer und Zink insgesamt unter 1 % liegt. Sonstige Materialien, darunter Lacke, Beschichtungen, elektrische Leitungen und Verkleidungsmaterialien, machen etwa 13,5 % aus. [55](FOTO)

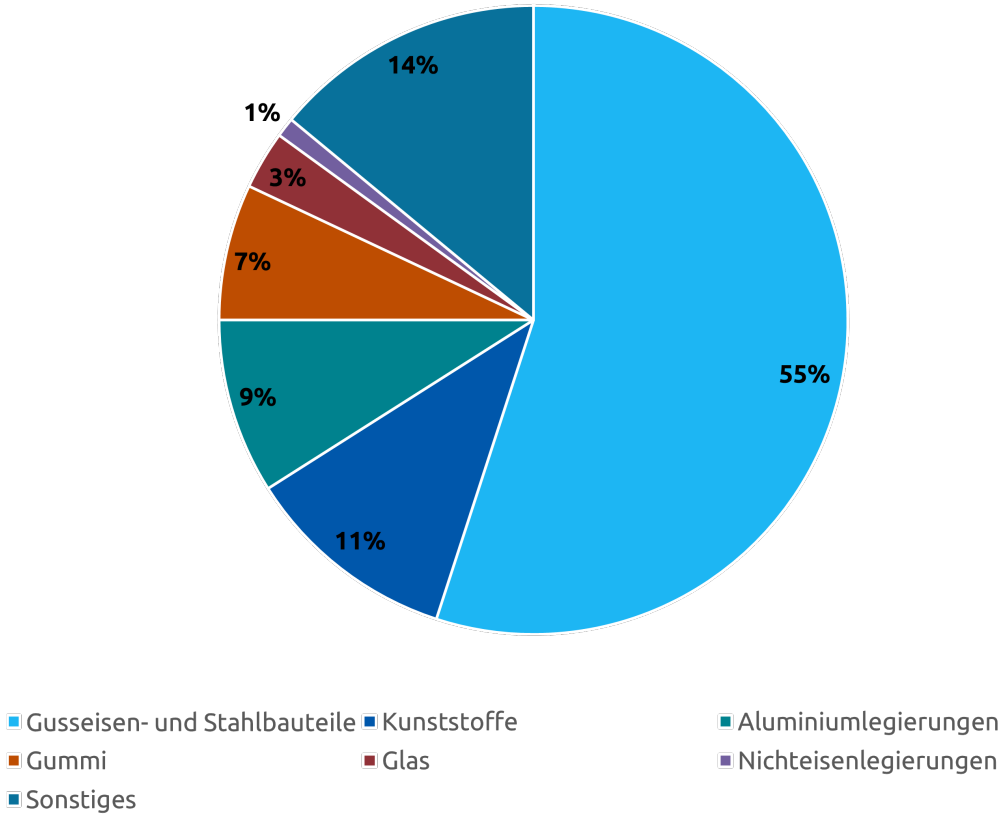


Figure 3.1: Verteilung der Werkstoffklassen im Automobilbau und deren relative Materialanteile. [55]

### 3.2.2 PLM-gestützte Materialdatenhaltung

Mit der zunehmenden Digitalisierung und der Verfügbarkeit umfangreicher Produkt- und Materialdaten gewinnen PLM-Systeme als zentrale Datenbasis für die Materialauswahl an Bedeutung. In PLM-Systemen werden Materialkennwerte, Simulationsergebnisse, Fertigungsdaten sowie Rückmeldungen aus Nutzung und Service über den gesamten Produktlebenszyklus hinweg konsolidiert. Diese integrierte Datenbasis bildet die Voraussetzung für den Einsatz KI-gestützter Methoden zur Unterstützung materialbezogener Entscheidungen. Künstliche Intelligenz ermöglicht es, große Mengen heterogener Material- und

Prozessdaten automatisiert zu analysieren und Zusammenhänge zu identifizieren, die mit klassischen Methoden nur schwer erkennbar sind. Auf dieser Grundlage können KI-Modelle alternative Werkstoffe vorschlagen, Zielkonflikte zwischen Gewicht, Kosten und Leistungsfähigkeit bewerten oder Materialentscheidungen hinsichtlich ihrer Auswirkungen auf den gesamten Produktlebenszyklus prognostizieren. [56]

### 3.2.3 Zielkonflikte zwischen Kosten, Gewicht und Performance

Ein typisches Anwendungsbeispiel ist der Vergleich konventioneller Werkstoffe wie Stahl mit Faserverbundmaterialien. Während kohlenstofffaserverstärkte Kunststoffe Vorteile hinsichtlich Gewicht, Festigkeit und Korrosionsbeständigkeit bieten, sind sie häufig mit höheren Material- und Prozesskosten verbunden. KI-gestützte Analysen innerhalb eines PLM-Systems ermöglichen es, diese Vor- und Nachteile datenbasiert abzuwägen und unter Berücksichtigung von Lebenszykluskosten, Fertigungsrestriktionen und Nachhaltigkeitszielen fundierte Entscheidungen zu treffen. [57]

Trotz des Potenzials neuer Werkstoffe bleibt Stahl aufgrund seiner Wirtschaftlichkeit, hohen Verfügbarkeit und kontinuierlichen Weiterentwicklung ein zentraler Werkstoff im Automobilbau. Die Kombination aus PLM-basiertem Materialdatenmanagement und KI-gestützter Entscheidungsunterstützung eröffnet jedoch neue Möglichkeiten, Materialauswahlprozesse zu optimieren und innovative sowie nachhaltige Fahrzeugkonzepte zu realisieren. [54]

#### Beispiel energie- und kostenintensiver Prozesse

Ein anschauliches Beispiel für die Bedeutung materialbezogener Entscheidungen sind Lackierprozesse im Automobilbau. Diese Prozesse sind energieintensiv, erfordern mehrere Prozessschritte sowie hohe Temperaturen und tragen erheblich zu den Umweltwirkungen eines Fahrzeugs bei. Die Wahl geeigneter Materialien und Oberflächen kann den Umfang oder sogar die Notwendigkeit bestimmter Beschichtungsprozesse reduzieren. Damit wird deutlich, dass Materialentscheidungen bereits in frühen Entwicklungsphasen maßgeblichen Einfluss auf nachgelagerte Fertigungsprozesse, Kostenstrukturen und Nachhaltigkeitskennzahlen haben. Genau an diesem Punkt setzt die KI-gestützte Materialentwicklung an, indem sie potenzielle Materialalternativen frühzeitig bewertet und energie- sowie ressourcenintensive Prozesse vermeidet. [**sustanibility**]

### 3.2.4 KI für die Materialentwicklung

[58]

## 3.3 Materialdatenbanken & Datenquellen

Zur Validierung der von KI generierten Materialeigenschaften werden offene und frei zugängliche Materialdatenbanken verwendet. Diese dienen als Referenzdatenbasis, um die Qualität und Aussagekraft der KI-basierten Vorhersagen zu bewerten. Zu den genutzten Datenquellen zählen unter anderem:

- **Materials Project**: Die modernisierte Web-Plattform des Materials Project ermöglicht die Exploration, Analyse und den Vergleich rechnerisch bestimmter Materialeigenschaften. Sie stellt Forschenden und Ingenieuren Zugriff auf eine umfangreiche und kontinuierlich aktualisierte Datenbasis zu anorganischen Materialien, Molekülen sowie deren physikalischen und chemischen Eigenschaften bereit [59].
- **Nachhaltigkeits- und LCA-Datenbanken**: Eine Sammlung von Daten, Werkzeugen und Fachpublikationen zur quantitativen Bewertung von Nachhaltigkeit. Dazu zählen unter anderem IDEMAT-LCA-Datenbanken, Eco-costs-Methodiken, Social-LCA-Werkzeuge sowie praxisorientierte Leitfäden zur Ökobilanzierung, zum True-Cost-Accounting und zu CSRD-Anwendungen [60].
- **NIST Materials Data Repository**: Eine offene Forschungsdatenplattform zur Speicherung, zum Austausch und zur Wiederverwendung von Materialdaten. Das Repository unterstützt die Ziele der Materials Genome Initiative (MGI) durch strukturierte Metadaten, community-basierte Datensammlungen sowie Programmierschnittstellen (APIs), um Auffindbarkeit, Vergleichbarkeit und Nachnutzung von Materialforschungsdaten zu ermöglichen [61].

Die in diesen Datenbanken enthaltenen Materialeigenschaften werden mit den von Citrine generierten Vorhersagen verglichen. Die Bewertung der Vorhersagequalität erfolgt anhand etablierter Fehlermetriken wie dem mittleren absoluten Fehler (MAE), dem quadratischen Mittelwertfehler (RMSE) sowie dem Bestimmtheitsmaß $R^2$.

# 4 Nachhaltigkeit in der Materialentwicklung

In den vergangenen Jahren haben zunehmende Umwelt- und Klimaprobleme sowie Herausforderungen wie Armut, wachsende soziale Ungleichheiten und gesellschaftliche Spannungen das Thema der nachhaltigen Entwicklung verstärkt in den Fokus gerückt. Nationale und internationale Institutionen, politische Entscheidungsträger sowie praxis- und forschungsnahe Akteure haben der sozialen und ökologischen Nachhaltigkeit weltweit erhöhte Aufmerksamkeit gewidmet. [62]

## 4.1 Grundlage der Nachhaltigkeit

Der Begriff „nachhaltige Entwicklung“ beschreibt die Idee, die Bedürfnisse der Gegenwart zu befriedigen, ohne die Chancen künftiger Generationen zu beeinträchtigen. Allerdings ist der Begriff „nachhaltig“ selbst schwer präzise zu definieren: Er umfasst wirtschaftliches Wohlergehen, soziale Gerechtigkeit und die Reduzierung von Umweltschäden. Diese Ziele sind nicht immer vereinbar. Dies ist besonders problematisch, wenn Umweltschäden pro Einheit wirtschaftlicher oder physischer Leistung bewertet werden: Steigt das Produktionsvolumen schneller als die Schäden pro Produktionseinheit sinken, nehmen die gesamten Umweltschäden zu. Es sind die absoluten, nicht die relativen, physischen Folgen, die eine Bedrohung für zukünftige Generationen darstellen. [**ashby2022materials**]

Trotz eines breiten Konsenses über die Bedeutung nachhaltiger Entwicklung wird deren konkrete inhaltliche Ausgestaltung und Zielsetzung jedoch nur selten explizit diskutiert und systematisch analysiert. Infolgedessen besteht die Gefahr, dass die praktische Umsetzung von Nachhaltigkeit durch die Unschärfe und Allgegenwärtigkeit des Begriffs eingeschränkt wird. [63]

Aufgrund der weit verbreiteten Verwendung des Nachhaltigkeitsbegriffs haben sich im Laufe der Zeit unterschiedliche Interpretationsansätze herausgebildet, die Nachhaltigkeit beispielsweise mit sozialer Verantwortung, Umweltmanagement oder unternehmerischer Nachhaltigkeit verknüpfen und häufig getrennt voneinander betrachten. Diese unterschiedlichen Perspektiven haben zugleich die Aufmerksamkeit auf die Rolle von Unternehmen gelenkt, deren Verantwortung und Beitrag zur nachhaltigen Entwicklung zunehmend hinterfragt werden. [64]

## 4.2 Relevanz der Nachhaltigkeit in Zahlen

Zwischen 1970 und 2024 nahm der globale Materialeinsatz von 30 auf 106 Mrd. Tonnen zu und geht mit erheblichen Umwelt- und Gesundheitsbelastungen einher. Die Gewinnung und Verarbeitung von Rohstoffen verursacht dabei mehr als 60% der klimarelevanten Emissionen und trägt wesentlich zu gesundheitsschädlicher Luftverschmutzung bei; Biomasse spielt insbesondere im Zusammenhang mit Biodiversitätsverlusten und Wasserstress eine zentrale Rolle. Zugleich bestehen deutliche Disparitäten im Materialkonsum zwischen Ländern unterschiedlicher Einkommensgruppen. Für Kontexte mit sehr hohem Konsumniveau wird die Reduktion der absoluten Materialnachfrage als Ansatz genannt, um den globalen Ressourcenverbrauch gegenüber historischen Trends um etwa 30% zu senken, ohne gesellschaftliche Entwicklung grundsätzlich auszuschließen. [**IRP2024_GlobalResourcesOutlook_Pres**

Im Jahr 2019 lag der Primärenergiebedarf der weltweiten Primäraluminium-Herstellung entlang der gesamten Prozesskette - vom Abbau bis zur Gießerei - bei 186 GJ pro Tonne. Demgegenüber erforderte die Produktion von Recyclingaluminium lediglich 8,3 GJ pro Tonne, was einer Energieeinsparung von rund 95,5% entspricht. [**EuropeanAluminium2025_EnvironmentalPro**

Diese Zahlen verdeutlichen, dass nachhaltige Materialien nicht nur aus ökologischer Sicht relevant sind, sondern auch erhebliche wirtschaftliche Auswirkungen besitzen und einen direkten Einfluss auf das gesellschaftliche Wohlbefinden haben.

## 4.3 Nachhaltigkeit der Materialien

Angesichts des zunehmenden Drucks durch nationale und internationale Regulierungen sowie durch gesellschaftliche Erwartungen werden Unternehmen zunehmend dazu verpflichtet, Prinzipien sozialer und ökologischer Verantwortung systematisch in ihre Strategien, Organisationsstrukturen und Managementsysteme zu integrieren. [65]

Insbesondere die jüngsten europäischen Regulierungen, wie die Ökodesign-Verordnung für nachhaltige Produkte (ESPR), erfordern eine deutlich beschleunigte Transformation hin zu nachhaltigen Produkten und Prozessen. Diese Anforderungen lassen sich jedoch ohne zusätzliche technologische Hilfsmittel, insbesondere ohne den Einsatz datengetriebener Methoden und Künstlicher Intelligenz, nur schwer erfüllen. [66]

Gleichzeitig sind Entwicklungszyklen für neue Materialien traditionell sehr zeit- und kostenintensiv und können mehrere Jahre in Anspruch nehmen, insbesondere wenn sie auf klassischen experimentellen und iterativen Entwicklungsansätzen basieren. Diese langen Entwicklungszeiten stehen zunehmend im Spannungsfeld zu regulatorischen Anforderungen und verkürzten Innovationszyklen, was den Bedarf an daten- und KI-gestützten Methoden zur Beschleunigung der Materialentwicklung weiter erhöht. [67]

Vor diesem Hintergrund gewinnt der Einsatz datengetriebener Methoden und Künstlicher Intelligenz zunehmend an Bedeutung, da sie es ermöglichen, Nachhaltigkeitsaspekte bereits in frühen Phasen der Materialentwicklung systematisch zu berücksichtigen und klassische, zeitintensive Entwicklungszyklen zu verkürzen.

[68] [69]

## 4.4 Lebenszyklusbetrachtung (LCA)

Die Lebenszyklusbetrachtung (Life Cycle Assessment, LCA) ist ein etabliertes Instrument zur Bewertung von Umweltauswirkungen. [**ilgin2010environmentally**]

### 4.4.1 Grundlage der LCA

LCA bewertet den Ressourceneinsatz über den gesamten Lebensweg eines Produkts. Dieser umfasst die Rohstoffgewinnung, die Herstellungs- und Nutzungsphase sowie die Entsorgung bzw. Abfallbewirtschaftung. In den vergangenen Jahren hat sich die Methodik der LCA stark weiterentwickelt und findet inzwischen breite Anwendung in Wissenschaft und Praxis. Ziel dieser Arbeit ist es, einen Überblick über aktuelle methodische Entwicklungen der LCA zu geben. Der Schwerpunkt liegt dabei auf Bereichen, in denen zuletzt besonders intensive Fortschritte erzielt wurden, sowie auf neu entstehenden Fragestellungen. [**finnveden2009recent**]

Im Zusammenhang mit der Ziel- und Untersuchungsrahmendefinition (Goal and Scope) wird insbesondere die Unterscheidung zwischen attributionaler und konsequenzieller LCA diskutiert. Diese Differenzierung ist auch für die Sachbilanz (Inventory Analysis) relevant, etwa bei der Festlegung von Systemgrenzen, bei der Datenerhebung und bei Allokationsfragen. Darüber hinaus werden Entwicklungen im Bereich von Datenbanken sowie Ansätze der Input–Output-LCA und hybriden LCA hervorgehoben. Für die Wirkungsabschätzung (Life Cycle Impact Assessment) werden sowohl grundlegende Modellierungsmerkmale als auch neuere Fortschritte in einzelnen Wirkungskategorien und bei der Gewichtung dargestellt. In der Interpretationsphase steht insbesondere die Unsicherheitsanalyse im Fokus. Abschließend werden die jüngsten Entwicklungen vor dem Hintergrund zentraler Stärken und Grenzen der LCA eingeordnet. [**hauschild2018life**]

### 4.4.2 Methodische Weiterentwicklung

Ab dem Beginn des 21. Jahrhunderts lässt sich eine zunehmende Bedeutung und verstärkte Wahrnehmung der LCA feststellen. Im Jahr 2002 initiierten das United Nations

Environment Programme (UNEP) und die Society for Environmental Toxicology and Chemistry (SETAC) eine internationale Partnerschaft, die als Life Cycle Initiative bekannt wurde (39). Deren Ziel war es, Life-Cycle-Thinking stärker in der Praxis zu verankern und die unterstützenden Instrumente durch bessere Daten und Indikatoren weiterzuentwickeln (39). Parallel dazu gewann Life-Cycle-Thinking auch in der europäischen Politik an Bedeutung, was sich unter anderem in der Mitteilung der Europäischen Kommission zur Integrated Product Policy (IPP) widerspiegelt (40). Zudem wurde der Ansatz in thematische Strategien zur nachhaltigen Ressourcennutzung (41) sowie zur Abfallvermeidung und zum Recycling (42) integriert. In ihrer IPP-Mitteilung von 2003 betonte die Europäische Kommission ausdrücklich die Bedeutung der LCA und die Notwendigkeit, die Anwendung von Life-Cycle-Thinking bei den relevanten Stakeholdern der IPP zu fördern (40). Als Reaktion darauf wurde 2005 die European Platform on Life Cycle Assessment eingerichtet, mit dem Auftrag, die Verfügbarkeit, den Austausch und die Nutzung qualitätsgesicherter Lebenszyklusdaten, Methoden und Studien zu stärken, um belastbare Entscheidungsgrundlagen in EU-Politik und Wirtschaft bereitzustellen (43). [**guinee2011life**]

### 4.4.3 Relevanz der LCA für diese Arbeit

Für diese Arbeit ist die Lebenszyklusbetrachtung (Life Cycle Assessment, LCA) von zentraler Bedeutung, da sie ein standardisiertes und quantitatives Rahmenwerk zur Bewertung der Nachhaltigkeit von Materialien bereitstellt. Die in dieser Arbeit eingesetzte KI-Software wird daher nicht isoliert anhand der technischen Vorhersagegenauigkeit bewertet, sondern im Hinblick auf ihre Fähigkeit, materialbezogene Nachhaltigkeitskennzahlen bereits in frühen Entwicklungsphasen abzuschätzen.

Zur Validierung der KI-basierten Vorhersagen werden etablierte LCA-Datenbanken herangezogen, insbesondere die IDEMAT-Datenbank (vgl. Kapitel 3.3). IDEMAT dient dabei als Referenz für ökologische Kenngrößen und ermöglicht den Vergleich KI-generierter Materialeigenschaften mit lebenszyklusorientierten Nachhaltigkeitsindikatoren. Dadurch wird eine methodische Verbindung zwischen KI-gestützter Materialentwicklung und der LCA als Bewertungsrahmen hergestellt.

### 4.4.4 Systemgrenzen

In der Life Cycle Assessment (LCA) definieren Systemgrenzen den betrachteten Umfang des Produktsystems, d. h. welche Prozesse und Lebenszyklusphasen in die Bilanzierung einbezogen bzw. ausgeschlossen werden. [**el2010sustainable**] Typische Abgrenzungsvarianten sind:

- **Cradle-to-Gate** (von der Wiege bis zum Werkstor): Umfasst Rohstoffgewinnung, Vorprodukte sowie Herstellung bis zum Verlassen des Werks (inkl. vorgelagerter Lieferkette). Nutzungs- und End-of-Life-Phase sind nicht enthalten. [**kim2016cradle**]
- **Cradle-to-Grave** (von der Wiege bis zur Bahre): Umfasst den vollständigen Lebenszyklus von der Rohstoffgewinnung über Verarbeitung/Produktion und Distribution bis zur Nutzung sowie Entsorgung bzw. Behandlung am Lebensende (z. B. Deponie, Verbrennung oder Recyclingpfade). [**mcdonough2010cradle**]
- **Cradle-to-Cradle** (von der Wiege zur Wiege): Erweitert Cradle-to-Grave um eine geschlossene Kreislaufführung, bei der Materialien nach der Nutzung gezielt in technische oder biologische Kreisläufe zurückgeführt werden. Der Fokus liegt auf Wiederverwendung, hochwertigem Recycling (Closed-Loop) und der Vermeidung von Abfall als Endzustand. [**braungart2009cradle**]

Bei der Nutzung- und End-of-Life-Phase ist schwer Daten zu erfassen. Aus diesem Grund wird in dieser Arbeit die Systemabgrenzung *Cradle-to-Gate* gewählt.

### 4.4.5 $CO_2$-Fußabdruck

Eine zentrale Metrik zur Bewertung von Umweltauswirkungen ist der $\mathrm{CO_2}$-Fußabdruck. Anthropogene Aktivitäten verändern die Konzentrationen relevanter Treibhausgase in der Atmosphäre, darunter Kohlendioxid ($\mathrm{CO_2}$), Ozon ($\mathrm{O_3}$), Distickstoffoxid ($\mathrm{N_2O}$) und Methan ($\mathrm{CH_4}$). [**schonbeckzukunft**] Damit geht eine anhaltende Zunahme der Treibhausgasbelastung einher, die mit hohen Emissionsmengen verbunden ist.

Der anthropogene Anstieg dieser Treibhausgase verstärkt den Treibhauseffekt und führt zu einer Erwärmung von Atmosphäre, Ozean und Land. [**ipcc_ar6_wgi_spm**] Mit zunehmender globaler Erwärmung verändern sich zudem zentrale Klimawirkungen und Extremereignisse; insbesondere nehmen in vielen Regionen Häufigkeit und/oder Intensität von Hitzeextremen sowie von Dürren und kombinierten heiß-trockenen Ereignissen zu, was unter anderem die Austrocknung von Böden und Wasserstress begünstigen kann. [**ipcc_ar6_wgi_spm**, **ipcc_ar6_wgi_ch11**] Vor diesem Hintergrund hat sich der $\mathrm{CO_2}$-Fußabdruck als zentrale Kenngröße etabliert, um Klimawirkungen entlang von Produkten, Prozessen oder Wertschöpfungsketten quantitativ zu bewerten und Reduktionspotenziale abzuleiten. [**ipcc_ar6_syr_spm**]

Auch in Deutschland ist die Minderung von Treibhausgasemissionen politisch und rechtlich verankert: Das Bundes-Klimaschutzgesetz sieht u. a. eine Reduktion der Emissionen um mindestens $65\,\%$ bis 2030 und mindestens $88\,\%$ bis 2040 (jeweils gegenüber 1990) sowie das Ziel der Netto-Treibhausgasneutralität bis 2045 vor. [**bmukn_ksg**, **uba_minderungsziele**]

In dieser Arbeit nimmt der $CO_2$-Fußabdruck eine zentrale Rolle ein, da die Bewertung und Optimierung nachhaltiger Materialien wesentlich von den verursachten Treibhausgasemissionen abhängt.

[**gutowski2013global**] [**davis2011supply**]

# 5 Methodik der KI-gestützten Materialanalyse(CRISM-DM)

## 5.1 Methodik CRISP-DM

Die sorgfältige und strukturierte Analyse von Daten ist ein essenzieller Bestandteil aktueller datengetriebener Entscheidungsprozesse. Um Data-Mining-Projekte effizient und nachvollziehbar umzusetzen, hat sich die CRISP-DM - Methodik als branchenübergreifender Standard erwiesen. Dieses Kapitel widmet sich der Beschreibung der sechs Phasen der CRISP-DM-Methodik sowie ihrer Anwendung im Kontext des Data Collection Assistant. [**bemthuis2025crisp**]

(Bild hier eifügen und bilder woanders wie tabelle)

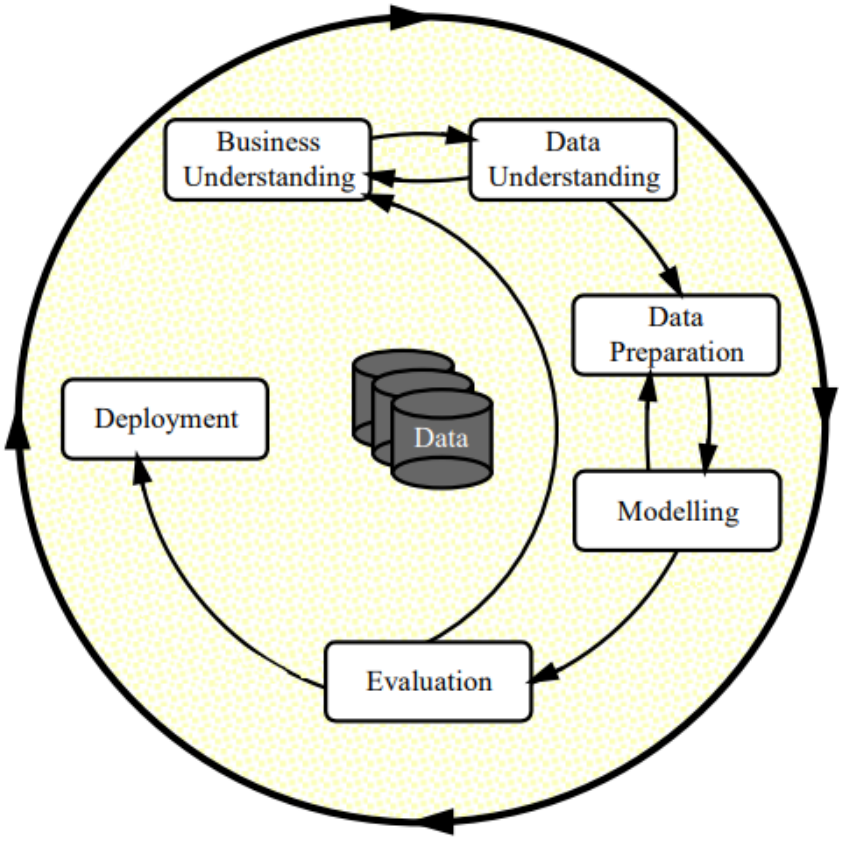


Figure 5.1: Phasen des aktuellen CRISP-DM-Prozessmodells [**asdsasdas**]

Im olgenden werden die einzelnen Phasen kurz beschrieben:

- **Business Understanding:** In dieser Phase werden Ziele, Anforderungen und Rahmenbedingungen aus fachlich-geschäftlicher Sicht präzisiert. Anschließend werden

die Ziele in ein Data-Mining-Problem überführt und ein erster Projektplan erstellt. [**wirth2000crisp**]

- **Data Understanding:** Beginnend mit einer initialen Datensammlung werden die Daten exploriert, um Datenqualität zu prüfen, erste Erkenntnisse zu gewinnen und relevante Teilmengen zu identifizieren. Business Understanding und Data Understanding sind eng verknüpft, da Problemdefinition und Planung ein grundlegendes Verständnis der verfügbaren Daten erfordern. [**baijens2020applying**]
- **Data Preparation:** Umfasst alle Schritte zur Erstellung des finalen Datensatzes für die Modellierung, typischerweise iterativ und ohne feste Reihenfolge (z. B. Selektion, Bereinigung, Feature Engineering und Transformationen). [**saltz2017predicting**]
- **Modeling:** Auswahl und Anwendung geeigneter Modellierungsverfahren sowie Parametrisierung (z.B. Tuning). Mehrere Verfahren können für denselben Problemtyp geeignet sein; teilweise sind spezifische Datenformate erforderlich. [**chapman_crispdm_2000**]
- **Evaluation:** Vertiefte Prüfung der Modelle im Hinblick auf die Geschäftsziele und Review der durchgeführten Schritte. Ziel ist die Entscheidung, ob und wie die Ergebnisse genutzt werden. [**bemthuis2025crisp**]
- **Deployment:** Aufbereitung und Bereitstellung der Ergebnisse für die Nutzung (z. B. Bericht oder implementierter Prozess). Häufig führen Anwender die Umsetzung durch; daher sollten erforderliche Maßnahmen frühzeitig definiert werden. [**saltz2017predicting**]

# 6 KI-gestützte nachhaltige Materialentwicklung

...

## 6.1 Toolsübersicht - Citrine

Citrine Informatics ist ein auf Materialinformatik spezialisiertes Unternehmen, das Künstliche Intelligenz zur beschleunigten Entwicklung und Optimierung von Materialien einsetzt. Der Ansatz von Citrine basiert auf der Kombination physikbasierter Domänenkenntnisse mit maschinellen Lernverfahren, um aus heterogenen Materialdaten robuste Vorhersagemodelle abzuleiten. Ziel ist es, Zusammenhänge zwischen Zusammensetzung, Prozessparametern, Mikrostruktur und Materialeigenschaften systematisch zu erfassen und für das gezielte Design neuer Werkstoffe nutzbar zu machen. Durch diese datengetriebene Methodik können Entwicklungszyklen verkürzt, experimentelle Aufwände reduziert und nachhaltigere Materiallösungen schneller identifiziert werden. Insbesondere im industriellen Umfeld ermöglicht Citrine Informatics eine wissensbasierte Entscheidungsunterstützung, indem Materialanforderungen mit Leistungs-, Kosten- und Nachhaltigkeitszielen in Einklang gebracht werden. [88]

## 6.2 APIs

Software wird in der Regel über eine Benutzeroberfläche direkt von Menschen verwendet. Zunehmend wird Software jedoch nicht mehr ausschließlich von Endnutzern genutzt, sondern auch von anderen Softwaresystemen. Dies erfordert eine spezielle Form der Schnittstelle, die als Application Programming Interface (API) bezeichnet wird. APIs stellen einen standardisierten Mechanismus zur Anbindung, Integration und Erweiterung von Softwaresystemen dar. Sie werden insbesondere beim Aufbau verteilter Softwaresysteme eingesetzt, deren Komponenten lose miteinander gekoppelt sind. Die in diesem Zusammenhang betrachteten APIs sind überwiegend Web-APIs, die als Webservices realisiert sind und Ressourcen über gängige Webtechnologien bereitstellen. Typische Anwendungsbeispiele für APIs finden sich in mobilen Anwendungen, Cloud-basierten Systemen, Webanwendungen sowie in intelligenten Endgeräten. Ein wesentliches Merkmal von APIs ist

ihre einfache, klare und wiederverwendbare Struktur, die eine effiziente Integration unterschiedlicher Anwendungen ermöglicht. Im Gegensatz zu klassischen Benutzeroberflächen sind APIs für Endnutzer in der Regel nicht sichtbar und werden nicht direkt von Menschen bedient. Stattdessen arbeiten sie im Hintergrund und werden von anderen Softwaresystemen oder Anwendungen aufgerufen. APIs dienen somit primär der Maschine-zu-Maschine-Kommunikation sowie der Kopplung und Integration mehrerer Softwaresysteme. Die direkten Nutzer von APIs sind in der Regel Softwareentwickler, die Anwendungen oder Lösungen auf Basis dieser Schnittstellen implementieren. Aus diesem Grund müssen APIs mit einem klaren Fokus auf die Bedürfnisse der Entwickler konzipiert werden, die sie in neue oder bestehende Anwendungen integrieren. Diese Perspektive verdeutlicht die Notwendigkeit eines spezifischen, entwicklerzentrierten Ansatzes bei der Gestaltung und Implementierung von APIs. [79]

### 6.2.1 REST API

Für diese Arbeit wird REST API benutzt um die Plattformen gemeinsam zu verbinden.

REST (Representational State Transfer) ist ein architektonischer Ansatz zur Gestaltung von Diensten, die plattform- und umgebungsübergreifend genutzt werden können, um Interoperabilität im Kontext des World Wide Web zu gewährleisten. Zu den zentralen Merkmalen dieser Architektur zählen insbesondere Zustandslosigkeit sowie die Eignung für den plattformunabhängigen Zugriff. REST hat sich als weit verbreiteter und standardisierter Ansatz zur Bereitstellung von Diensten über das Internet etabliert. REST-basierte Application Programming Interfaces (APIs) sind zudem ein integraler Bestandteil moderner Microservice-Architekturen. Darüber hinaus existieren Forschungsarbeiten, die die REST-Architektur zur Unterstützung verteilter Systeme erweitern. RESTful APIs, häufig auch als Web-APIs bezeichnet, bestehen aus sogenannten Endpunkten. Jeder Endpunkt repräsentiert eine konkret implementierte Funktionalität eines Geschäftsprozesses. Der Zugriff auf diese Schnittstellen erfolgt in der Regel über das Hypertext Transfer Protocol (HTTP) unter Verwendung standardisierter Methoden wie GET, POST, PUT und DELETE. Die Identifikation und Adressierung der Ressourcen erfolgt dabei über eine eindeutige URI (Uniform Resource Identifier). Eine zentrale Herausforderung bei der Nutzung von REST-Schnittstellen bestand lange Zeit in der Festlegung eines einheitlichen Nachrichtenformats für Anfragen und Antworten. Anfangs wurden REST-APIs häufig informell beschrieben. Mit der Zeit etablierte sich jedoch JSON (JavaScript Object Notation) als de-facto-Standard für den Datenaustausch. JSON basiert auf einem textuellen Format und ist sowohl für Menschen gut lesbar als auch für Maschinen einfach zu verarbeiten, unabhängig von Plattform und Netzwerkumgebung. [80]

[68] [69]

# 7 Evaluierung des KI-Einsatzes

## 7.1 Evaluierungsstrategie

Da in der Materialentwicklung häufig kontinuierliche Materialeigenschaften wie Festigkeit, Dichte, Wärmeleitfähigkeit oder Emissionskennwerte vorhergesagt werden, liegt der Fokus dieser Arbeit auf Regressionsmetriken. [25]

# 8 Beispiel-Kapitel: Noch ein Kapitel

blabla

## 8.1 Abschnitt mit Coding

Der folgende Quelltext wird auch im Quelltextverzeichnis referenziert:

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from apyori import apriori

movie_data = pd.read_csv('./movie_dataset.csv', header = None)
num_records = len(movie_data)
print(num_records)
```

Quelltext 8.1: `PrintMovieDB.py`

## 8.2 Noch ein Abschnitt mit Coding

Blabla

# 9 Zusammenfassung

Dieses Kapitel enthält die Zusammenfassung der Arbeit mit Fazit und Ausblick.

## 9.1 Fazit

...

## 9.2 Ausblick

...

# A Beispiel-Anhang: Testanhang

Anhänge werden am Ende Ihrer Arbeit vor dem Literaturverzeichnis und dem Index eingefügt.

## A.1 Abschnitt im Anhang

Blabla

## A.2 Noch ein Abschnitt im Anhang

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non

enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

# B Beispiel-Anhang: Noch ein Testanhang

nochmal: lipsum ...

# Bibliography


[1] John Stark. “Product lifecycle management (PLM)”. In: *Product lifecycle management (volume 1) 21st Century paradigm for product realisation*. Springer, 2022, pp. 1–32.

[2] Michael W Grieves. “Product lifecycle management: the new paradigm for enterprises”. In: *International Journal of Product Development* 2.1-2 (2005), pp. 71–84.

[3] Rachuri Sudarsan et al. “A product information modeling framework for product lifecycle management”. In: *Computer-aided design* 37.13 (2005), pp. 1399–1411.

[4] John Stark. “Product lifecycle management”. In: *Product Lifecycle Management: 21st century paradigm for product realisation*. Springer, 2011, pp. 1–16.

[5] Angelo Corallo et al. “Defining product lifecycle management: a journey across features, definitions, and concepts”. In: *International Scholarly Research Notices* 2013.1 (2013), p. 170812.

[6] Jingran Li et al. “Big data in product lifecycle management”. In: *The International Journal of Advanced Manufacturing Technology* 81.1 (2015), pp. 667–684.

[7] Mike Philpotts. “An introduction to the concepts, benefits and terminology of product data management”. In: *Industrial Management & Data Systems* 96.4 (1996), pp. 11–17.

[8] Ivica Crnkovic, Ulf Asklund, and Annita Persson Dahlqvist. *Implementing and integrating product data management and software configuration management*. Artech House, 2003.

[9] D Tony Liu and X William Xu. “A review of web-based product data management systems”. In: *Computers in industry* 44.3 (2001), pp. 251–262.

[10] Michael Grieves and John Vickers. “Digital twin: Mitigating unpredictable, undesirable emergent behavior in complex systems”. In: *Transdisciplinary perspectives on complex systems: New findings and approaches*. Springer, 2016, pp. 85–113.

[11] Siemens Digital Industries Software. *Teamcenter X: Cloud PLM Software*. Siemens. 2026. URL: `https://plm.sw.siemens.com/en-US/teamcenter/teamcenter-x-cloud-plm/` (visited on 03/12/2026).

[12] LJ Fogel, AJ Owens, and MJ Walsh. “Artificial Intelligence Through”. In: (1966).

[13] Andreas Holzinger et al. “Causability and explainability of artificial intelligence in medicine”. In: *Wiley interdisciplinary reviews: data mining and knowledge discovery* 9.4 (2019), e1312.

[14] Joshua B Tenenbaum et al. “How to grow a mind: Statistics, structure, and abstraction”. In: *science* 331.6022 (2011), pp. 1279–1285.

[15] Michael I Jordan and Tom M Mitchell. “Machine learning: Trends, perspectives, and prospects”. In: *Science* 349.6245 (2015), pp. 255–260.

[16] Yoshua Bengio, Ian Goodfellow, Aaron Courville, et al. *Deep learning*. Vol. 1. MIT press Cambridge, MA, USA, 2017.

[17] Martín Abadi et al. "{TensorFlow}: a system for {Large-Scale} machine learning". In: *12th USENIX symposium on operating systems design and implementation (OSDI 16)*. 2016, pp. 265–283.

[18] Muhammed Golec et al. "Artificial intelligence (ai): Foundations, trends and future directions". In: *Telematics and Informatics Reports* (2025), p. 100265.

[19] Christopher M Bishop. *Neural networks for pattern recognition*. Oxford university press, 1995.

[20] Marcus J Neuer. *Unüberwachtes Lernen*. Springer, 2024, pp. 151–183.

[21] Leslie Pack Kaelbling, Michael L Littman, and Andrew W Moore. "Reinforcement learning: A survey". In: *Journal of artificial intelligence research* 4 (1996), pp. 237–285.

[22] Yuxi Li. "Deep reinforcement learning: An overview". In: *arXiv preprint arXiv:1701.07274* (2017).

[23] Xiaojin Jerry Zhu. "Semi-supervised learning literature survey". In: (2005).

[24] Jie Gui et al. "A survey on self-supervised learning: Algorithms, applications, and future trends". In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 46.12 (2024), pp. 9052–9071.

[25] Umberto Michelucci and Francesca Venturini. "Best Practices for Machine Learning Experimentation in Scientific Applications". In: *arXiv preprint arXiv:2511.21354* (2025).

[26] Cort J Willmott and Kenji Matsuura. "Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance". In: *Climate research* 30.1 (2005), pp. 79–82.

[27] Tianfeng Chai, Roland R Draxler, et al. "Root mean square error (RMSE) or mean absolute error (MAE)". In: *Geoscientific model development discussions* 7.1 (2014), pp. 1525–1534.

[28] A Colin Cameron and Frank AG Windmeijer. "An R-squared measure of goodness of fit for some common nonlinear regression models". In: *Journal of econometrics* 77.2 (1997), pp. 329–342.

[29] Rudresh Dwivedi et al. "Explainable AI (XAI): Core ideas, techniques, and solutions". In: *ACM computing surveys* 55.9 (2023), pp. 1–33.

[30] Bokai Liu et al. "Explainable artificial intelligence (XAI) for material design and engineering applications: a quantitative computational framework". In: *International Journal of Mechanical System Dynamics* 5.2 (2025), pp. 236–265.

[31] Alejandro Barredo Arrieta et al. "Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI". In: *Information fusion* 58 (2020), pp. 82–115.

[32] Yasunobu Nohara et al. "Explanation of machine learning models using shapley additive explanation and application for real data in hospital". In: *Computer Methods and Programs in Biomedicine* 214 (2022), p. 106584.

[33] Muhammad Rehman Zafar and Naimul Khan. "Deterministic local interpretable model-agnostic explanations for stable explainability". In: *Machine Learning and Knowledge Extraction* 3.3 (2021), pp. 525–541.

[34] Bokai Liu, Nam Vu-Bac, and Timon Rabczuk. “A stochastic multiscale method for the prediction of the thermal conductivity of Polymer nanocomposites through hybrid machine learning algorithms”. In: *Composite Structures* 273 (2021), p. 114269.

[35] Bokai Liu and Weizhuo Lu. “Surrogate models in machine learning for computational stochastic multi-scale modelling in composite materials design”. In: *International Journal of Hydromechatronics* 5.4 (2022), pp. 336–365.

[36] François Bry et al. “Aktuelles Schlagwort" Semi-strukturierte Daten"”. In: *Informatik-Spektrum* 4 (2001), pp. 230–233.

[37] Avita Katal, Mohammad Wazid, and Rayan H Goudar. “Big data: issues, challenges, tools and good practices”. In: *2013 Sixth international conference on contemporary computing (IC3)*. Ieee. 2013, pp. 404–409.

[38] Daniel W Barowy et al. “FlashRelate: extracting relational data from semi-structured spreadsheets using examples”. In: *ACM SIGPLAN Notices* 50.6 (2015), pp. 218–228.

[39] Arvind Arasu and Hector Garcia-Molina. “Extracting structured data from web pages”. In: *Proceedings of the 2003 ACM SIGMOD international conference on Management of data*. 2003, pp. 337–348.

[40] Salvador García et al. “Big data preprocessing: methods and prospects”. In: *Big data analytics* 1.1 (2016), p. 9.

[41] Salvador García, Julián Luengo, Francisco Herrera, et al. *Data preprocessing in data mining*. Vol. 72. Springer, 2015.

[42] Dorian Pyle. *Data preparation for data mining*. morgan kaufmann, 1999.

[43] SS Baskar, L Arockiam, and S Charles. “A systematic approach on data pre-processing in data mining”. In: *Compusoft* 2.11 (2013), p. 335.

[44] Ian H Witten et al. “Practical machine learning tools and techniques”. In: *Data mining*. Vol. 2. 4. Elsevier Amsterdam, The Netherlands. 2005, pp. 403–413.

[45] José A Sáez, Julián Luengo, and Francisco Herrera. “Predicting noise filtering efficacy with data complexity measures for nearest neighbor classification”. In: *Pattern Recognition* 46.1 (2013), pp. 355–364.

[46] Julián Luengo, Salvador García, and Francisco Herrera. “On the choice of the best imputation methods for missing values considering three groups of classification methods”. In: *Knowledge and information systems* 32.1 (2012), pp. 77–108.

[47] Sultan Alneyadi, Elankayer Sithirasenan, and Vallipuram Muthukkumarasamy. “A survey on data leakage prevention systems”. In: *Journal of Network and Computer Applications* 62 (2016), pp. 137–152.

[48] Shikang Chen et al. “Blockchain applications in PLM towards smart manufacturing”. In: *The International Journal of Advanced Manufacturing Technology* 118.7 (2022), pp. 2669–2683.

[49] Fatemeh Nargesian et al. “Learning feature engineering for classification.” In: *Ijcai*. Vol. 17. 2017, pp. 2529–2535.

[50] Renee Kroon et al. “Small bandgap polymers for organic solar cells (polymer material development in the last 5 years)”. In: *Polymer Reviews* 48.3 (2008), pp. 531–582.

[51] X-D Xiang et al. “A combinatorial approach to materials discovery”. In: *Science* 268.5218 (1995), pp. 1738–1740.

[52] Brian Tomlinson. “Principles of effective materials development”. In: *English language teaching materials: Theory and practice* (2010), pp. 81–108.

[53] J Kihara et al. *Computer Aided Innovation of New Materials*. Elsevier, 2012.

[54] Mekonnen Asmare Fentahun and Mahmut Ahsen Savas. “Materials used in automotive manufacture and material selection using ashby charts”. In: *Int. J. Mater. Eng* 8.3 (2018), pp. 40–54.

[55] Tetiana Pavlivna Hovorun et al. “Modern materials for automotive industry”. In: (2017).

[56] Sarah Mandy Munsch et al. *Anwendung von KI für die Materialoptimierung im Bauwesen*. Bundesanstalt für Materialforschung und-prüfung (BAM), 2024.

[57] Mohammad-Reza Pendar et al. “Review of coating and curing processes: Evaluation in automotive industry”. In: *Physics of Fluids* 34.10 (2022).

[58] Ralf T Kreutzer and Marie Sirrenberg. *Künstliche Intelligenz verstehen*. Springer, 2019.

[59] The Materials Project. *Materials Project: Next-Generation Platform*. Lawrence Berkeley National Laboratory. 2026. URL: `https://next-gen.materialsproject.org/` (visited on 03/12/2026).

[60] Sustainability Impact Metrics Foundation. *Data, Tools and Books for Eco-costs and LCA*. Sustainability Impact Metrics (TU Delft). 2026. URL: `https://www.ecocostsvalue.com/data-tools-books/` (visited on 03/12/2026).

[61] National Institute of Standards and Technology (NIST). *NIST Materials Data Repository*. U.S. Department of Commerce. 2026. URL: `https://materialsdata.nist.gov/` (visited on 03/12/2026).

[62] Julie Battilana and Silvia Dorado. “Building sustainable hybrid organizations: The case of commercial microfinance organizations”. In: *Academy of management Journal* 53.6 (2010), pp. 1419–1440.

[63] Rob Gray. “Is accounting for sustainability actually accounting for sustainability... and how would we know? An exploration of narratives of organisations and the planet”. In: *Accounting, organizations and society* 35.1 (2010), pp. 47–62.

[64] George Joseph. “Ambiguous but tethered: An accounting basis for sustainability reporting”. In: *Critical perspectives on Accounting* 23.2 (2012), pp. 93–106.

[65] Jean-Pascal Gond et al. “Configuring management control systems: Theorizing the integration of strategy and sustainability”. In: *Management accounting research* 23.3 (2012), pp. 205–223.

[66] Giorgia Faraca et al. “Ecodesign for Sustainable Products Regulation: Study on new product priorities”. In: (2024).

[67] Anders MS Ø Jakobsen and Torben Tambo. “Current state of sustainability representation product lifecycle management systems and future perspectives: a comparative evaluation”. In: *Cleaner Logistics and Supply Chain* 16 (2025), p. 100229.

[68] Nelson K Akafuah et al. “Evolution of the automotive body coating process—A review”. In: *Coatings* 6.2 (2016), p. 24.

[69] M Tisza. “Advanced materials for automotive application”. In: *IOP Conference series: materials science and engineering*. Vol. 47. 1. 2013, p. 012010.

[70] Antti Saaksvuori and Anselmi Immonen. *Product lifecycle management*. Springer, 2005.

[71] Rafa Abdul et al. “Designing Enterprise Solutions with Siemens Teamcenter for Enhanced Usability”. In: *International Journal of Research and Analytical Reviews (IJRAR)* 7.1 (2020), p. 477.

[72] Siwar Chibani and François-Xavier Coudert. “Machine learning approaches for the prediction of materials properties”. In: *Apl Materials* 8.8 (2020).

[73] Stuart Russell, Peter Norvig, and Artificial Intelligence. “A modern approach”. In: *Artificial Intelligence. Prentice-Hall, Egnlewood Cliffs* 25.27 (1995), pp. 79–80.

[74] Eugene Charniak. *Introduction to artificial intelligence*. Pearson Education India, 1985.

[75] Ashish Vaswani et al. “Attention is all you need”. In: *Advances in neural information processing systems* 30 (2017).

[76] Richard S Sutton, Andrew G Barto, et al. *Reinforcement learning: An introduction*. Vol. 1. 1. MIT press Cambridge, 1998.

[77] Leo Breiman et al. *Classification and regression trees*. Chapman and Hall/CRC, 2017.

[78] Trevor Hastie et al. *The elements of statistical learning: data mining, inference, and prediction*. Vol. 2. Springer, 2009.

[79] Xiaodong Gu et al. “Deep API learning”. In: *Proceedings of the 2016 24th ACM SIGSOFT international symposium on foundations of software engineering*. 2016, pp. 631–642.

[80] Mark Masse. *REST API design rulebook: designing consistent RESTful web service interfaces*. " O’Reilly Media, Inc.", 2011.

[81] Gareth James et al. *An introduction to statistical learning: with applications in R*. Vol. 103. Springer, 2013.

[82] Max Kuhn and Kjell Johnson. *Feature engineering and selection: A practical approach for predictive models*. Chapman and Hall/CRC, 2019.

[83] Vladimir Vapnik. *The nature of statistical learning theory*. Springer science & business media, 2013.

[84] G Uma. “Transition and Evolution of Data into Big Data in the 21st Century”. In: ().

[85] Jean-Marc Adamo. *Data mining for association rules and sequential patterns: sequential and parallel algorithms*. Springer Science & Business Media, 2001.

[86] David Foster. *Generative deep learning*. " O’Reilly Media, Inc.", 2022.

[87] D Lakshmi et al. *Explainable AI (XAI) for sustainable development: Trends and applications*. CRC Press, 2024.

[88] Citrine Informatics. *Citrine Informatics: AI Platform for Materials and Chemicals Development*. Citrine Informatics, Inc. 2026. URL: `https://citrine.io/` (visited on 03/12/2026).